



Universidad Nacional del Nordeste



Facultad de Ciencias Exactas y Naturales y Agrimensura

Carrera: Licenciatura en Sistemas de Información

Cátedra: Base de Datos II

Año: 2020

Grupo 2

Tema de monografía:

FASE DE MINERÍA DE DATOS. TÉCNICAS

PREDICTIVAS DE MODELIZACIÓN

Integrantes:

	Apellidos y Nombres	L.U. N°
	Bartolucci Soto, Cecilia Lorena	16798
	Burguener, Rocío	12896
	Fernández, Erika Ruth	13918
	González, Claudio Rodolfo	14450
	Quarín, Emanuel Néstor Antonio	10556
	Ramírez, Gregorio Iván	10123

Índice de Contenido

1-	Introducción	1
2-	Concepto de Minería de Datos.....	2
2.1-	Herramientas.....	3
3-	El proceso de extracción del conocimiento (KDD).....	4
4-	Técnicas de minería de datos	7
4.1	Técnicas predictivas	9
4.2	Técnicas Descriptivas	11
4.3	Técnicas auxiliares	11
5-	Clasificación AD HOC: Análisis Discriminante.....	12
5.1.-	Hipótesis En El Modelo Discriminante	13
5.2.-	Estimación Del Modelo Discriminante.....	13
5.3.-	Clasificación Mediante El Modelo Discriminante	14
6-	Sistema de minería de datos.....	16
7-	Conclusión	19
8-	Bibliografía	20

Índice de Figuras

Figura 1 – Jerarquía en una base de datos	1
Figura 2 – Procesamiento de datos ETL (extraído de: InetSoft)	2
Figura 3 – Herramientas de toma de decisiones.	4
Figura 4 – Etapas del proceso KDD.	5
Figura 5 – Técnicas de Minería de datos.....	7

Índice de Tabla

Tabla 1 – Sistemas de minerías de datos más utilizados.	16
--	----

1- Introducción

En la actualidad, los datos son la materia prima bruta de toda organización y en donde a partir del momento en que el usuario les atribuye algún significado especial, es decir comienzan a tomar gran relevancia, pasan a convertirse en información.

Hay tantos datos y una gran cantidad de decisiones que tomar. Las organizaciones de todo el mundo se están enfrentando a este dilema. Los datos están creciendo, pero ¿y su capacidad para tomar decisiones de acuerdo con esos enormes volúmenes de datos? ¿También están creciendo?

La analítica predictiva ayuda a evaluar lo que sucederá en el futuro. La minería de datos (**Data Mining**) busca los patrones ocultos en los datos que pueden utilizarse para predecir el comportamiento futuro. Las empresas, los científicos y los gobiernos han utilizado este enfoque por años para transformar los datos en conocimientos proactivos [1].

Y cuando esa información comienza a tomar experiencia y valores nos referimos al conocimiento. El conocimiento se deriva de la información, así como la información se deriva de los datos.



Figura 1 – Jerarquía en una base de datos

[Fuente: https://www.sinnexus.com/business_intelligence/piramide_negocio.aspx]

La capacidad de generar y almacenar información creció considerablemente en los últimos tiempos, se ha estimado que la cantidad de datos en el mundo almacenados en bases de datos se duplica cada 20 meses. Es así que hoy las organizaciones tienen gran cantidad de datos almacenados y organizados, pero a los cuales no les pueden analizar eficientemente en su totalidad.

Algunos datos estadísticos determinan que aproximadamente el 80% de la información se obtiene con técnicas avanzadas que trataremos a lo largo de este documento, y el 20% restante es aquella información conocida por la empresa.

El Descubrimiento de Conocimiento en Bases de Datos (**KDD**) apunta a procesar automáticamente grandes cantidades de datos para encontrar conocimiento útil en ellos, de esta manera permitirá al usuario el uso de esta información valiosa para su conveniencia. Por lo que se desarrolla el siguiente trabajo de investigación para dar a conocer los conceptos, el proceso **ETL** (extracción, transformación y carga de la información) (**figura 2 – Pag. 2**), técnicas y sistemas involucrados en el proceso de minería de datos que permiten a las instituciones poder tomar las mejores decisiones, en [2].




Figura 2 – Procesamiento de datos ETL (extraído de: InetSoft)

[Fuente: <https://www.astera.com/es/tipo/blog/datos-etl/>]

2- Concepto de Minería de Datos

La Minería de Datos (**Data Mining**) Se define como un proceso de descubrimiento de nuevas y significativas relaciones, patrones y tendencias para examinar grandes volúmenes de datos.

El uso de herramientas informáticas encaminan el análisis hacia técnicas especializadas, que en su conjunto, se denominan **Minería de Datos o Data Mining**. Estas técnicas utilizan tecnologías de reconocimiento de patrones, redes neuronales, lógica difusa, algoritmos genéticos, entre otros métodos avanzados en el análisis de datos.

Al principio, la finalidad de los sistemas de información, era dar soporte a procesos básicos de la organización (ventas, producción, personal, etc.), es decir, **sistemas de información para la gestión**.

Actualmente, se exigen nuevas prestaciones de los sistemas de información, se busca contar en las organizaciones con **sistemas de información para la toma de decisiones**.

En respuesta a estas emergentes necesidades surgieron nuevas herramientas de negocio (DSS o Decision Support Systems) que coexisten: EIS, OLAP, consultas e informes y las propias herramientas de MINERÍA DE DATOS.

2.1- Herramientas

2.1.1 - EIS (Executive Information System): proporciona a los directivos acceso a la información de estado sus actividades de gestión. Informa rápidamente sobre cambios. La información solicitada puede ser en gran medida numérica (ventas semanales, nivel de stocks, balances parciales, etc) y es representada en forma gráfica al estilo de las hojas de cálculo.

2.1.2- OLAP (On-Line Analytical Processing): son más genéricas, funcionan sobre un sistema de información (transaccional o almacén de datos) y permiten realizar combinaciones de datos mucho más complejas y ambiciosas, con objetivos de análisis más estratégicos. En general están basadas en sistemas o interfaces multidimensionales que brindan la información de una manera matricial. Permiten facilidades para “manejar” y “transformar” datos, producen “otros” y son muy eficientes en el análisis ya que producen diferentes vistas de los mismos datos.

2.1.3 - Sistema de Informes o consultas avanzadas: se basan en sistemas relacionales u objeto-relacionales y el resultado se brinda en forma tabular.

2.1.4 - Herramientas de minería de datos: permiten extraer patrones, tendencias y regularidades para describir, comprender mejor los datos y para predecir comportamientos futuros. La Minería de Datos analiza los datos y el resto de las herramientas facilitan el acceso a la información para que el análisis sea más efectivo, es decir, son instrumentos de apoyo.

Además, debe contarse con almacenes de datos (**Data Warehouse**), siendo el sistema de información central en todo proceso. Un almacén de datos es una colección de datos orientada a un dominio, integrada, no volátil y variante en el tiempo para ayudar en la toma de decisiones. Un almacén es un conjunto de datos históricos, in-

ternos o externos descriptivos de un contexto. Que permiten aplicar eficientemente herramientas para resumir, describir y analizar datos con el fin de la toma estratégica de decisiones.

Las fuentes internas y externas están separadas. El origen de datos internos proviene de una base de datos transaccional. Pero también existen otras fuentes externas de información.

Para cargar o alimentar los datos se utiliza un sistema llamado **ETL (Extraction, transformation, Load)** que se encarga de la lectura de los datos, incorporación de nuevos datos, creación de claves etc. En la siguiente se explica cómo funcionan estos sistemas, en [3].

No obstante, los almacenes de datos no son imprescindibles, ya que se puede aplicar Minería de Datos sobre un fichero de Datos.

Sin embargo, la ventaja de organizar la información en almacenes radica en que se reduce la complejidad de aplicar minería de datos, a medio y largo plazo cuando se tienen enormes volúmenes de datos, aumentan con el tiempo, provienen de fuentes externas heterogéneas o van a cambiar de manera arbitraria y no predefinida.




Figura 3 – Herramientas de toma de decisiones.

[Fuente: <https://www.gestiopolis.com/definicion-herramientas-la-inteligencia-negocios/>]

3- El proceso de extracción del conocimiento (KDD)

La Extracción de conocimiento está principalmente relacionado con el proceso de descubrimiento conocido como **Knowledge Discovery in Databases (KDD)**, que se refiere al proceso no-trivial de descubrir conocimiento e información potencialmente útil dentro de los datos contenidos en algún repositorio de información. Es un proceso

iterativo que exhaustivamente explora volúmenes muy grandes de datos para determinar relaciones.

La minería de datos no es más que una fase del **KDD**, que integra los métodos de aprendizaje y estadísticos para obtener hipótesis de PATRONES y MODELOS.

KDD es un proceso que extrae información de calidad que puede usarse para dibujar conclusiones basadas en relaciones o modelos dentro de los datos.




Figura 4 – Etapas del proceso KDD.

[Fuente:

http://exa.unne.edu.ar/depar/areas/informatica/SistemasOperativos/Mineria_de_Datos_y_KDD.pdf]

El KDD comienza con la **RECOPILACIÓN E INTEGRACIÓN DE LA INFORMACIÓN** a partir de unos datos iniciales de que se dispone (fase de selección de datos).

Las primeras fases del KDD determinan que las fases sucesivas sean capaces de extraer conocimiento valido y útil a partir de la información original.

Frecuentemente, la información que se quiere investigar sobre un cierto dominio de la organización se encuentra en bases de datos (Database) y otras fuentes muy diversas, tanto internas como externas (en general la información se encuentra ordenada en almacenes de datos). La disponibilidad de grandes volúmenes de información en esta fase conlleva a la necesidad de usar técnicas de muestreo para la selección de datos.

La fase siguiente del KDD integra la EXPLORACIÓN, la LIMPIEZA (**criba**) de datos (**Data Cleaning**) y la TRANSFORMACION de datos. Se debe eliminar el mayor número posible de datos erróneos o inconsistentes (limpieza) e irrelevante (**criba**). Aquí, se utilizan herramientas de consulta (**Query tools**) y herramientas estadísticas (**Statistics tools**) casi exclusivamente. En la exploración se usan técnicas de análisis exploratorio de datos como los histogramas y los diagramas de caja, tallo y hojas, que ayudan a detectar datos anómalos o atípicos (**outliers**). La presencia de datos atípicos y valores

desaparecidos (**data missing**) puede llevarnos a usar algoritmos robustos, a filtrar la información, a reemplazar valores mediante técnicas de imputación y a transformar datos continuos en discretos mediante técnicas de discretización.

Entre las técnicas avanzadas de transformación se encuentran las de reducción y aumento de la dimensión.

La fase siguiente en el KDD es la propia minería de datos que se llevara a cabo a partir del desarrollo de modelos predictivos y descriptivos (**Model Development**) y mediante el análisis de datos (**Data Analysis**).

Una vez recogidos los datos de interés, un explorador puede decidir qué tipo de patrón quiere descubrir. El tipo de conocimiento que se desea extraer va a marcar claramente la técnica de minería de datos a utilizar.

Para seleccionar y validar los modelos anteriores es necesaria una nueva fase consistente en el uso de criterios de evaluación de hipótesis. El despliegue del modelo a veces es trivial pero otras veces requiere un proceso de implementación o interpretación.

Una fase posterior del KDD es la relativa a la difusión y uso del conocimiento derivado de las técnicas de minería de datos a través de los modelos correspondientes que habitualmente desembocan en la generación de resultados (**output Generation**). El modelo puede tener muchos usuarios y puede necesitar difusión, lo que requiere expresarse de una manera comprensible para distribuirse en la organización. En esta fase se utilizan herramientas de visualización (**Visualization tools**), presentación (**Presentation tools**) y transformación de datos (**Data Transformation tools**).

Por lo tanto, en el proceso de extracción del conocimiento KDD se presenta la secuencia de fases siguiente:

SELECCIÓN ➡ EXPLORACIÓN ➡ LIMPIEZA ➡ TRANSFORMACIÓN ➡
MINERÍA DE DATOS ➡ EVALUACIÓN ➡ DIFUSIÓN.

En la **fase de selección** se **integran y recopilan** los datos, se determinan las fuentes de información que pueden ser útiles y donde conseguirlas, se identifican y seleccionan las variables relevantes en los datos y aplican las técnicas de muestreo adecuadas. Todo ello se facilita disponiendo de un almacén de datos con la información en formato común y sin inconsistencias. Dado que los datos provienen de diferentes fuentes, es necesaria su **exploración** mediante técnicas de análisis exploratorio de datos, buscando entre otras cosas la distribución de los datos, su simetría y normalidad y las correlaciones existentes en la información. A continuación, es necesaria la **limpieza** de los datos, ya que pueden contener valores atípicos, valores faltantes y valores erróneos.

os. En esta fase se analiza la influencia de datos atípicos, se imputan los valores faltantes y se eliminan o corrigen los datos incorrectos.

A continuación, si es necesario, se lleva a cabo la **transformación** de los datos, generalmente mediante técnicas de reducción o aumento de la dimensión y escalado simple y multidimensional, entre otras. Usualmente, las cuatro primeras fases se engloban bajo el nombre de preparación de datos.

En la **fase de minería de datos**, se decide cual es la tarea a realizar (clasificar, agrupar, etc.) y se elige la técnica a utilizar.

En la **fase de evaluación e interpretación** se evalúan los patrones y se analizan por los expertos, y si es necesario se vuelve a las fases anteriores para una nueva iteración.

Finalmente, en la **fase de difusión** se hace uso del nuevo conocimiento y se hace partícipe de él a todos los posibles usuarios.

4- Técnicas de minería de datos

La clasificación inicial de las técnicas de minería de datos distingue entre **técnicas predictivas**, en las que las variables pueden clasificarse inicialmente en dependientes e independientes, **técnicas descriptivas**, en las que todas las variables tienen inicialmente el mismo estatus y **técnicas auxiliares**.



Figura 5 – Técnicas de Minería de datos.

[Fuente: Ing. Cathy Pamela Guevara Vega, Universidad de las Fuerzas Armadas, Ecuador]

Las **técnicas predictivas** especifican el modelo para los datos en base a un conocimiento teórico previo. El modelo supuesto para los datos debe contrastarse después del proceso de minería de datos antes de aceptarlo como válido. Formalmente, la aplicación de todo modelo debe superar las fases de *identificación objetiva* (a partir de los datos se aplican reglas que permitan identificar el mejor modelo posible que ajuste los datos), *estimación* (proceso de cálculo de los parámetros del modelo elegido para los datos en la fase de identificación), *diagnosis* (proceso de contraste de la validez del modelo estimado) y *predicción* (proceso de utilización del modelo identificado, estimado y validado para predecir valores futuros de las variables dependientes).

Dentro de estas técnicas, se incluyen todos los tipos de regresión, series temporales, análisis de la varianza y covarianza, análisis discriminante, árboles de decisión, redes neuronales, algoritmos genéticos y técnicas bayesianas. Tanto los árboles de decisión, como las redes neuronales y el análisis discriminante son a su vez *técnicas de clasificación* que pueden extraer perfiles de comportamiento o clases, siendo el objetivo construir un modelo que permita clasificar cualquier nuevo dato.

En las **técnicas descriptivas** no se asigna ningún papel predeterminado a las variables. No se supone la existencia de variables dependientes ni independientes y tampoco se supone la existencia de un modelo previo para los datos. Los modelos se crean automáticamente partiendo del reconocimiento de patrones. En este grupo se incluyen las técnicas de clustering y segmentación (que también son técnicas de clasificación en cierto modo), las técnicas de asociación y dependencia, las técnicas de análisis exploratorio de datos y las técnicas de reducción de la dimensión (factorial, componentes principales, correspondencias, etc.) y de escalamiento multidimensional.

Las **técnicas auxiliares** son herramientas de apoyo más superficiales y limitadas. Se trata de nuevos métodos basados en técnicas estadísticas descriptivas, consultas e informes y enfocados en general hacia la *verificación*.

Las **técnicas de clasificación** pueden pertenecer tanto al grupo de técnicas predictivas (discriminante, árboles de decisión y redes neuronales) como a las descriptivas (clustering y segmentación).

Las **técnicas de clasificación predictivas** se denominan técnicas de clasificación **ad hoc** y clasifican individuos u observaciones dentro de grupos previamente definidos.

Las **técnicas de clasificación descriptivas** se denominan técnicas de clasificación **post hoc** porque realizan clasificación sin especificación previa de los grupos.

4.1-Técnicas predictivas

4.1.1- Regresión: Se usa para predecir los valores ausentes de una variable basándose en su relación con otras variables de la tabla de datos. Hay regresión lineal, no lineal, logística, logarítmica, univariada, multivariada, entre otras. Es la más utilizada para formar relaciones entre datos. Rápida y eficaz, pero insuficiente en espacios multidimensionales donde puedan relacionarse más de dos variables.

4.1.2- Análisis de la varianza (Anova) El análisis de varianza sirve para comparar si los valores de un conjunto de datos numéricos son significativamente distintos a los valores de otro o más conjuntos de datos. Se utiliza para analizar la relación entre una variable dependiente métrica y varias variables independientes no métricas. El objetivo es determinar si diversas muestras proceden de poblaciones con igual media. Los valores no métricos de las variables independientes determinarán una serie de grupos en la variable dependiente.

4.1.3- Series Temporales Una serie temporal consiste en una colección de observaciones realizadas de manera secuencial en el tiempo. Una serie de tiempo es considerada continua cuando las observaciones son hechas de forma continua en el tiempo. Si las observaciones tienen lugar solo en momentos específicos entonces es considerada como una serie temporal discreta. Existen múltiples objetivos que motivan el análisis de series temporales y están enfocados principalmente tanto a la extracción de información representativa como a la posibilidad predecir su comportamiento futuro. El más importante es el *descubrimiento de patrones*, que es la tarea no trivial de descubrir patrones interesantes en una serie de tiempo.

4.1.4- Métodos Bayesianos Una red bayesiana es un grafo acíclico dirigido en el que cada nodo representa una variable y cada arco una dependencia probabilística, en la cual se especifica la probabilidad condicional de cada variable dados sus padres. La variable a la que apunta el arco es dependiente (causa-efecto) de la que está en el origen de éste. La topología o estructura de la red nos da información sobre las dependencias probabilísticas entre las variables, pero también sobre las independencias condicionales de una variable (o conjunto de variables) dada otra variable(s). El obtener una red bayesiana a partir de datos, es un proceso de aprendizaje que se divide en dos etapas: el aprendizaje estructural y el aprendizaje paramétrico [Pearl, 1988]. La primera de ellas, consiste en obtener la estructura de la red bayesiana, es decir, las relaciones de dependencia e independencia entre las variables involucradas. La segunda etapa, tiene como finalidad obtener las probabilidades a priori y condicionales requeridas a partir de una estructura dada.

4.1.5- Algoritmos Genéticos: Los AG utilizan una analogía del comportamiento natural observado en la biología. Se trabaja con una población de "individuos", en donde cada uno representa una solución potencial a un problema dado. A cada uno de los individuos se les asigna un "valor de aptitud", de acuerdo a qué tan buena sea su solución al problema. Luego los individuos con aptitudes más altas son seleccionados para replicarse, mutarse o "cruzarse" con otros individuos de la población. Esto produce nuevos individuos, los cuales comparten algunas características de cada uno de sus padres. Una nueva población de posibles soluciones es producida seleccionando los mejores individuos de la actual generación. El proceso se repite hasta satisfacer unos criterios de terminación.

4.1.6- Clasificación de ad hoc

4.1.6.1- Discriminante El análisis discriminante es una técnica estadística multivariante cuya finalidad es describir (si existen) las diferencias entre grupos de objetos sobre los que se observan determinadas variables (variables discriminantes). Los dos principales usos del análisis discriminante son la clasificación de objetos en grupos preestablecidos y la identificación de variables descriptivas que mejor definan la pertenencia a grupos.

4.1.6.2- Árboles de decisión Un Árbol de decisión es un conjunto de condiciones organizadas en una estructura jerárquica. La decisión final depende del camino que se toma desde la raíz del árbol. Las opciones posibles a partir de una condición son excluyentes, es decir, en todo momento se llegará a una sola decisión. Los árboles de decisión permiten clasificar los datos en grupos basados en los valores de las variables. El mecanismo consiste en elegir un atributo como raíz y desarrollar el árbol según las variables más significativas.

4.1.6.3- Redes Neuronales El objetivo que da origen a las **Redes Neuronales**, es construir un modelo que sea capaz de reproducir el método de aprendizaje del cerebro humano. Las células encargadas de este aprendizaje son las **neuronas** interconectadas entre sí a través de complejas redes.

Son capaces de extraer patrones y detectar tramas que son muy difíciles de apreciar por el ser humano u otras técnicas computacionales, siendo la facilidad de implementación de estos métodos lo que ha facilitado su popularidad. Estas RNA se caracterizan por tres partes fundamentales: la topología de la red (propagación hacia adelante o recurrentes), la regla de aprendizaje (supervisado, no supervisado, reforzado, etc...) y el tipo de entrenamiento.

4.2- Técnicas Descriptivas

4.2.1- Reglas de asociación Este tipo de técnicas se emplea para establecer las posibles relaciones o correlaciones entre distintas acciones o sucesos aparentemente independientes; pudiendo reconocer como la ocurrencia de un suceso o acción puede inducir o generar la aparición de otros. Son utilizadas cuando el objetivo es realizar análisis exploratorios, buscando relaciones dentro del conjunto de datos.

4.2.2- Análisis exploratorio El Análisis Exploratorio de Datos (**E.D.A.: Exploratory data analysis**) es un conjunto de técnicas estadísticas cuya finalidad es conseguir un entendimiento básico de los datos y de las relaciones existentes entre las variables analizadas. Para conseguir este objetivo el E.D.A. proporciona métodos sistemáticos sencillos para organizar y preparar los datos, detectar fallos en el diseño y recogida de los mismos, tratamiento y evaluación de datos ausentes (missing) e identificación de casos atípicos (outliers).

4.2.3- Reducción de dimensión Si es posible describir con precisión valores de p variables por un pequeño subconjunto $r < p$ de ellas, se habrá reducido la dimensión del problema a costa de una pequeña pérdida de información. Éste es el principal objetivo de la técnica y fue desarrollado por Hotelling (1933), aunque sus orígenes se encuentran en los ajustes ortogonales por mínimos cuadrados introducidos por K. Pearson (1901).

4.2.4- Clasificación post hoc

4.2.4.1- Clustering Las técnicas de Clustering son las que utilizando algoritmos matemáticos se encargan de agrupar objetos. Usando la información que brindan las variables que pertenecen a cada objeto se mide la similitud entre los mismos, y una vez hecho esto se colocan en clases que son muy similares internamente (entre los miembros de la misma clase) y a la vez diferente entre los miembros de las diferentes clases.

4.2.4.2- Segmentación La segmentación puede definirse como el proceso de dividir un todo (población, consumidores, etc.) en grupos uniformes más pequeños que tengan características semejantes denominados segmentos. La segmentación suele realizarse según los valores de determinadas variables que son los que fijan sus características.

4.3- Técnicas auxiliares El Proceso Analítico de Transacciones (**OLAP**) es parte de una gama de herramientas de toma de decisiones. Las consultas tradicionales y los

reportes describen lo que hay en la base de datos. **OLAP** va más allá, es usado para responder porque ciertas cosas son ciertas. Un analista genera una serie de patrones y relaciones hipotéticas usando consultas (mediante herramientas como SQL) para aprobarlos o rechazarlos. OLAP es en esencia un proceso deductivo.

Pero, ¿qué pasa cuando el número de variables por analizar es por docenas o incluso cientos? Se vuelve más difícil el encontrar una buena hipótesis, analizar la base de datos con **OLAP**, verificarla o desaprobala.

La minería de datos es diferente de **OLAP** porque en lugar de verificar patrones hipotéticos, usa los mismos datos para descubrir tales patrones. Es en esencia un proceso inductivo.

5- Clasificación AD HOC: Análisis Discriminante

Es útil cuando se desea construir un modelo predictivo para pronosticar el grupo al que pertenece una observación a partir de determinadas características observadas que delimitan su perfil. Permite asignar o clasificar nuevos individuos u observaciones dentro de grupos previamente definidos: por ello es una técnica de clasificación ad hoc. Se lo conoce como análisis de la clasificación: su objetivo fundamental es: producir una regla o un esquema de clasificación que permite a un investigador predecir la población a la que es más probable que tenga que pertenecer una nueva observación o individuo.

El modelo predictivo define la relación entre: una variable dependiente (o endógena) no métrica (categórica), y , o varias variables independientes (o exógenas) métricas. La expresión es: $y = f(x_1, x_2, \dots, x_n)$. Las categorías de la variable dependiente definen los posibles grupos de pertenencia de las observaciones o individuos. Las variables independientes definen el perfil conocido de cada observación.

El objetivo esencial: es utilizar los valores conocidos de las variables independientes medidas sobre un individuo u observación (perfil) para predecir con qué categoría de la variable dependiente se corresponden para clasificar al individuo en la categoría adecuada.

Las dos grandes finalidades son: la descripción de diferencias entre grupos, y la predicción de pertenencia a grupos. La interpretación de las diferencias entre los grupos responde al objetivo de determinar: en qué medida un conjunto de características observadas en los individuos permite extraer dimensiones que diferencian a los grupos. Cuáles de estas características son las que en mayor medida contribuyen a tales di-

mensiones, es decir, cuáles presentan el mayor poder de discriminación. Las características usadas para diferenciar entre los grupos reciben el nombre de **variables discriminantes**.

Al análisis para valorar el grado en que las variables independientes contribuyen a la diferenciación entre los grupos se le denomina **análisis discriminante descriptivo**. La predicción de pertenencia a los grupos requiere una o más ecuaciones matemáticas, denominadas **funciones discriminantes** que deben permitir la clasificación de nuevos casos a partir de la información que poseemos sobre ellos. Estas combinan una serie de características o variables de tal modo que su aplicación a un caso nos permite identificar el grupo al que más se parece: en este sentido se puede hablar del carácter predictivo del análisis discriminante.

5.1- Hipótesis En El Modelo Discriminante

El modelo del análisis discriminante requiere de una comprobación de determinados supuestos. La aplicación del análisis discriminante requiere que se cuente con: un conjunto de variables discriminantes (características conocidas de los individuos) y una variable nominal que define dos o más grupos (cada modalidad de la variable nominal se corresponde con un grupo diferente). Además, los datos deben corresponder a individuos o casos clasificados en dos o más grupos mutuamente excluyentes: cada caso corresponde a un grupo y sólo a uno.

Las variables discriminantes han de estar medidas en una escala de intervalo o de razón: lo cual permitiría el cálculo de medias y varianzas y la utilización de éstas en ecuaciones matemáticas. Teóricamente, no existen límites para el número de variables discriminantes: salvo la restricción de que no debe ser nunca superior al número de casos en el grupo más pequeño pero si es conveniente contar al menos con 20 sujetos por cada variable discriminante si queremos que las interpretaciones y conclusiones obtenidas sean correctas.

La aplicación del análisis discriminante se apoya en una serie de supuestos básicos: $\cup$ normalidad multivariante, homogeneidad de matrices de varianza-covarianza (homoscedasticidad), linealidad y ausencia de multicolinealidad.

5.2- Estimación Del Modelo Discriminante

Una vez comprobado el cumplimiento de los supuestos subyacentes al modelo matemático, se persigue: Obtener una serie de funciones lineales a partir de las variables independientes que permitan: Interpretar las diferencias entre los grupos. Clasificar a

los individuos en alguna de las subpoblaciones definidas por la variable dependiente. Estas funciones lineales se denominan funciones discriminantes.

La interpretación de la función discriminante podrá hacerse atendiendo a:

- Las posiciones relativas que determina para los casos.
- Los centroides de cada grupo.
- La relación entre las variables y la función: establecer la contribución de las distintas variables a la discriminación.
- Para examinar la posición relativa que ocupan los casos y los centroides de acuerdo con la función o funciones obtenidas: recurrir a las puntuaciones discriminantes: valores de la función discriminante para casos específicos.

C/u de las funciones discriminantes: representa un eje en el espacio discriminante. Permite determinar la posición de cualquier caso a lo largo de ese eje.

5.3- Clasificación Mediante El Modelo Discriminante

Las funciones discriminantes se utilizan para pronosticar el grupo al que quedará adscrito un nuevo caso no contemplado al extraer las funciones. La clasificación de un sujeto podría hacerse:

- A partir de sus valores en las variables discriminantes.
- En las funciones discriminantes.

La clasificación a partir de las funciones discriminantes es más cómoda y suele llevar a mejores resultados en la mayoría de los casos.

Los procedimientos para la clasificación se basan en la comparación de un caso con los centroides de grupo, a fin de ver a cuál de ellos resulta más próximo.

Uno de los procedimientos para asignar un caso a uno de los grupos se basa en las denominadas **funciones de clasificación por grupos**.

Examinando las puntuaciones obtenidas por un caso en c/u de las funciones de clasificación: se puede establecer a qué grupo ha de ser asignado. El caso será asignado a aquel grupo en el que se obtiene la puntuación más alta.

Otro procedimiento se basa en el cálculo de la distancia del caso a los centroides de cada uno de los grupos o funciones de distancia generalizada: el caso sería adscrito a aquel grupo con cuyo centroide existe una menor distancia.

Otro procedimiento para asignar un caso a uno de los grupos es utilizar las probabilidades de pertenencia al grupo. Un caso se clasifica en el grupo al que su pertenencia resulta más probable. El cálculo asume que todos los grupos tienen un tamaño similar: no se tiene en cuenta que a priori es posible anticipar una mayor probabilidad de pertenencia a un determinado grupo cuando en la población el porcentaje de sujetos que pertenece a cada grupo es muy diferente.

Incorporando las probabilidades a priori se consigue:

- Mejorar la predicción final.
- Reducir los errores de clasificación.

La regla de bayes sería útil para: calcular la probabilidad a posteriori de pertenencia del caso a un grupo.

Un caso será clasificado en el grupo en el que su pertenencia cuenta con una mayor probabilidad a posteriori.

Resulta interesante conocer para cada individuo: la máxima probabilidad, las probabilidades de pertenecer a otros grupos.

Un procedimiento muy útil es el mapa territorial: situar en el eje horizontal y en el vertical dos funciones discriminantes (o variables discriminantes). Separar en el plano resultante, por medio de líneas las zonas o territorios que ocuparían los sujetos clasificados en cada grupo. Cuando el número de funciones es mayor que dos: representar sólo las dos primeras, que son las que en mayor medida contribuyen a la separación de los grupos.

Para valorar la bondad de la clasificación realizada:

- Se aplica el procedimiento a los casos para los que se conoce su grupo de adscripción.
- Se comprueba si coinciden el grupo predicho y el grupo observado.

El porcentaje de casos correctamente clasificados indicaría la corrección del procedimiento.

La matriz de clasificación, también denominada matriz de confusión, permite presentar para los casos observados en un grupo:

- cuántos de ellos se esperaban en ese grupo.
- cuántos en los restantes.

Resulta fácil constatar qué tipo de errores de clasificación se producen.

6- Sistema de minería de datos

La **Tabla1** muestra los sistemas de minerías de datos más utilizados en el mercado junto con las técnicas que tratan cada uno de ellos, las plataformas sobre las que trabajan y las interfaces de lectura de datos.

Tabla 1 – Sistemas de minerías de datos más utilizados.

[Fuente: <http://www.isa.uniovi.es/docencia/redes/Apuntes.pdf>]

Producto	Compañía	Técnicas	Plataforma	Interfaz
Knowledge Seeker	Angross	Arboles de decisión	Win	ODBC
CART	Salford System	Arboles de Decisión	Win/Unix	
Clementine	SPSS	Amplio abanico	Win/Unix	OBDC
Data Surveyor	Data Distilleries	Amplio Abanico	Unix	OBDC
Gain Smart	Urban Science	Gráficos - Ganancias	Win/Unix	
Intelligent Miner	IBM	Amplio abanico	Unix(AIX)	IBM,DB 2
Micostrategy	Micostrategy	Datawarehouse	Win	Oracle
Polyanalyst	Megaputer	Simbólicas	Win	Oracle, ODBC
Darwin	Oracle	Amplio abanico	Win/Unix	Oracle
Enterprise Miner	SAS Institute	Amplio abanico	Win/Unix/Mac	
SIG MineSet	Silicon Graphics	Asociación y Clasificación	Unix	Oracle, Sybase, Informix
Wizsoft/Wizwhy	Wizsoft			

Los Sistemas de minería de datos que se verán son:

- ◆ **SPSS Clementine** es un sistema de minería de datos que contempla diferentes fuentes de datos (ASCII, Oracle, Informix, Sysbase, Ingres, etc), interfaz visual sencilla y distintas herramientas de minería de datos (redes neuronales, arboles de decisión, regresión, series temporales, cluster, etc). Trabaja bajo los Sistemas operativos Unix y Windows.
- ◆ **SAS Enterprise Miner** es una herramienta completa que incluye conexión a bases de datos (a través de **ODBC** y **SAS datasets**), muestreo e inclusión de variables derivadas, partición de la evaluación del modelo respecto a conjuntos de entrenamiento, validación y chequeo, distintas herramientas de minería de datos (algoritmos y tipos de árboles de decisión, redes neuronales, regresión y clustering, etc.), comparación de modelos y conversión de los modelos en código SAS. Dispone de un interfaz gráfico muy sencillo e incluye herramientas para flujo de proceso, tratando el proceso KDD como un proceso y las fases se pueden repetir, modificar y grabar.

Existen en el mercado otros sistemas que permiten realizar **Data Mining** a través de bases de datos. Concretamente, las bases de datos **Oracle** y **SQL Server** disponen de sistemas de minerías de datos asociados.

- ◆ **Oracle** dispone de herramientas de “Business Intelligence” y “Data Mining” (https://www.oracle.com/search/results/_/N-1jnZs0Z2bw?No=50&Nr=106&Nrpp=10&Ntk=SI-ALL5&Ntt=mineria+de+datos+en+oracle&lh=1&rgn=lad) que tienen una orientación más empresarial y de sistemas de información. También dispone de herramientas de **OLAP**, **Datawarehouse** e **Informes Avanzados**. Asimismo, presenta herramientas propias de minería de datos a través del producto **Oracle Darwin**.
- ◆ **Microsoft SQL Server** dispone del producto Analysis Services que implementa la minería de datos. Se fundamenta en el “**OLE DB for Data Mining**” e implementa una extensión del **SQL** que trabaja con **DMM** (Data Mining Model) que permite crear el modelo, entrenarlo y realizar predicciones. La versión SQL Server 2005, en su módulo **Analisis Services** cuenta con los algoritmos de minería de datos más avanzados entre los que se incluyen arboles de decisión y regresión, series temporales, agrupación clústeres, reglas de asociación, algoritmo Naive

Bayes y minería de textos. Dispone de un asistente y diseñador para minería de datos que permite construir modelos sofisticados a través de una interfaz fácil de usar. Además, se proporcionan gráficos de elevación y beneficios, por lo que podrá comparar y contrastar la calidad de los modelos antes de dedicarse a la distribución. Existe una representación clásica de los sistemas de minerías de datos cuya fuente es Elder Research (www.datamininglab.com).

7- Conclusión

La Minería de Datos ha sufrido transformaciones en los últimos años de acuerdo con cambios tecnológicos, de estrategias de marketing, la extensión de los modelos de compra en línea, etc. Los más importantes de ellos son:

La importancia que han cobrado los **datos no estructurados** (texto, páginas de Internet, etc.).

La necesidad de integrar los algoritmos y resultados obtenidos en sistemas operacionales, portales de Internet, etc. La exigencia de que los procesos funcionen prácticamente *en línea* (por ejemplo, en casos de fraude con una tarjeta de crédito).

Los **tiempos de respuesta**. El gran volumen de datos que hay que procesar en muchos casos para obtener un modelo válido es un inconveniente; esto implica grandes cantidades de tiempo de proceso y hay problemas que requieren una respuesta en tiempo real.

Por lo que estas tendencias nos guían hacia donde debemos enfocar las investigaciones tanto a nivel académico como comercial.

Para finalizar debemos mencionar que la importancia de la actividad de minería de datos y herramientas tradicionales, asumen que los datos que se usarán para construir los modelos contienen la información necesaria para lograr el propósito buscado: obtener suficiente conocimiento que pueda ser aplicado al *negocio* (o problema) para obtener un beneficio (o solución).

8- Bibliografía

A. De internet (1º parte)

[1] Sites.google, “La Minería de Datos de la A a la Z: Cómo Descubrir

Conocimientos y Crear Mejores Oportunidades.”, 2020. [Online].

Disponible en:

https://www.sas.com/es_ar/campaigns/analytics/mineria-datos.html?qclid=CjwKCAjw_Y_8BRBiEiwA5MCBJpUYfzM-J3SKJijFENWMaSEEMwCD3eZmx7ICrDV_wkYhi46-ERGkXhoCp2IQAvD_BwE

Fecha de último acceso: septiembre 2020.

B. Libros

[2] Pérez López, César – Santín González, Daniel, «Capítulo 13: Fase de Minería de Datos. Técnicas Predictivas de Modelización», en “*Minería de datos. Técnicas y herramientas*”, 1º Edición – 2º Reimpresión 2008. Madrid, Editorial Thomson: pp. 497-525

C. De internet (2º parte)

[3] EXA.UNNE.EDU.AR, “Base de Datos II – Trabajos de Adscriptos.”, 2020.

[Online]. Disponible en:

http://exa.unne.edu.ar/depar/areas/informatica/SistemasOperativos/Mineria_de_Datos_y_KDD.pdf

Fecha de último acceso: agosto 2020.

[4] Sites.google, “Definición y Herramientas de la Inteligencia de Negocios.”, 2020.

[Online]. Disponible en: <https://www.gestiopolis.com/definicion-herramientas-la-inteligencia-negocios/>

Fecha de último acceso: septiembre 2020

D. Consultas en Sitios Web

[5] Sites.google, “Minería de datos de Oracle Análisis predictivo escalable en la base de datos”, 2020. [Online]. Disponible en:

<https://www.oracle.com/database/technologies/advanced-analytics/odm.html>

Fecha de último acceso: Agosto - Septiembre 2020.

[6] Sites.google, “Minería de datos en SQL Server Management Studio”, 2020.
[Online]. Disponible en: [https://docs.microsoft.com/es-es/previous-versions/sql/sql-server-2008-r2/ms174471\(v=sql.105\)?redirectedfrom=MSDN](https://docs.microsoft.com/es-es/previous-versions/sql/sql-server-2008-r2/ms174471(v=sql.105)?redirectedfrom=MSDN)

Fecha de último acceso: Agosto - Septiembre 2020.