



Universidad Nacional del Nordeste



Facultad de Ciencias Exactas y Naturales y Agrimensura

Cátedra: Base de Datos II

Año: 2020

Grupo 1

Tema de monografía: Minería de Datos: Conceptos, Técnicas y Sistemas

Integrantes:

• Vargas, Cristian

L.U. N° 39513

• Acevedo Fulices

L.U. N° 33812

• Saucedo Miguel

L.U. N° 46288

Contenido

1. Introducción	4
2. Concepto de Minería de Datos	6
2.1 Herramientas	8
2.1.2 EIS (Executive Information System):	8
2.1.3 OLAP (On-Line Analytical Processing):	8
2.1.4 Sistema de Informes o consultas avanzadas	8
2.1.5 Herramientas de minería de datos	8
3. El proceso de extracción del conocimiento (KDD)	10
4. Técnicas de minería de datos	13
4.1 Técnicas predictivas	15
4.1.1 Regresión	15
4.1.2 Análisis de la varianza (Anova)	15
4.1.3 Series Temporales	15
4.1.4 Metodos Bayesianos	16
4.1.5 Algoritmos Geneticos	16
4.1.6 Clasificación de ad hoc	17
4.2 Técnicas Descriptivas	17
4.2.1 Reglas de asociación	17
4.2.2 Analisis exploratorio	18
4.2.3 Reducción de dimensión	18
4.2.4 Clasificación post hoc	18
4.3 Técnicas auxiliares	19
5. Sistema de minería de datos	20
6. Conclusión	23
7. Referencias	24

Índice de Figuras

Figura 1.1 Jerarquía de una Base de Datos.....	4
Figura 2.1 Relaciones entre los pasos del proceso.....	7
Figura 2.2 Introducción a la Minería de Datos – Orallo, Quintana y Ramirez.....	9
Figura 3.1 Etapas del Proceso KDD.....	10
Figura 4.1 Clasificación Técnicas Minería de Datos.....	14
Figura 4.2 Diagrama de Clasificación.....	15
Figura 5.1 Sistemas de Minería de Datos mas usados.....	20

1. Introducción

El data mining es una de las principales herramientas que se utilizan dentro de los programas de gestión del conocimiento como soporte a la toma de decisiones.

Las herramientas de data mining o minería de datos pueden responder a preguntas de negocios empresariales a priori no planteadas o que pueden consumir demasiado tiempo para ser resueltas.

En la actualidad, los datos son la materia prima bruta de toda organización y en donde a partir del momento en que el usuario les atribuye algún significado especial, es decir comienzan a tomar gran relevancia, pasan a convertirse en información. Y cuando esa información comienza a tomar experiencia y valores nos referimos al conocimiento. El conocimiento se deriva de la información, así como la información se deriva de los datos.

En la figura 1.1 se ilustra la jerarquía que existe en una base de datos entre datos, información y conocimiento.



Figura 1.1 Jerarquía de una Base de Datos

La capacidad de generar y almacenar información creció considerablemente en los últimos tiempos, se ha estimado que la cantidad de datos en el mundo almacenados en bases de datos se duplica cada 20 meses. Es así que hoy las organizaciones tienen gran cantidad de datos almacenados y organizados, pero a los cuales no les pueden analizar eficientemente en su totalidad.

Algunos datos estadísticos determinan que aproximadamente el 80% de la información se obtiene con técnicas avanzadas que trataremos a lo largo de este documento, y el 20% restante es aquella información conocida por la empresa.

El Descubrimiento de Conocimiento en Bases de Datos (KDD) apunta a procesar automáticamente grandes cantidades de datos para encontrar conocimiento útil en ellos, de esta manera permitirá al usuario el uso de esta información valiosa para su conveniencia. Por lo que se desarrolla el siguiente trabajo de investigación para dar a conocer los conceptos, el proceso ETL (extracción, transformación y carga de la información), técnicas y

sistemas involucrados en el proceso de minería de datos que permiten a las instituciones poder tomar las mejores decisiones.

Los programas de gestión del conocimiento se complementan con distintas herramientas además del data mining, como puede ser el data warehousing o el groupware. El data mining, como herramienta de búsqueda de información, se utiliza como sistema de apoyo a la toma de decisiones de las altas direcciones de las empresas. Las técnicas de data mining se centran en analizar el gran volumen de datos, que en una primera selección pueden ser pertinentes, pero que la aplicación de técnicas de selección ceñida a una determinada demanda, reduce el tamaño de los datos eligiendo las variables más influyentes en el problema.

2. Concepto de Minería de Datos

La minería de datos puede definirse inicialmente como un proceso de descubrimiento de nuevas y significativas relaciones, patrones y tendencias al examinar cantidades de datos.

La disponibilidad de grandes volúmenes de información y el uso generalizado de herramientas informáticas ha transformado el análisis de datos orientándolo hacia determinadas técnicas especializadas englobadas bajo el nombre de minería de datos o Data Mining.

Las técnicas de minería de datos perdiguen el descubrimiento automático del conocimiento contenido en la información almacenada de modo ordenado en grandes bases de datos. Estas técnicas tienen como objetivo descubrir patrones, perfiles y tendencias a través del análisis de los datos utilizando tecnologías de reconocimiento de patrones, redes neuronales, lógica difusa, algoritmos genéticos y otras técnicas avanzadas de análisis de datos.

Inicialmente la finalidad de los sistemas de información era recopilar información sobre una parcela determinada para ayudar en la toma de decisiones. Con la informatización de las organizaciones y la aparición de aplicaciones de software, la principal finalidad de los sistemas de información es dar soporte a los procesos básicos de la organización, las organizaciones exigen nuevas prestaciones de los sistemas de información.

La generación de un modelo de minería de datos forma parte de un proceso mayor que incluye desde la formulación de preguntas acerca de los datos y la creación de un modelo para responderlas, hasta la implementación del modelo en un entorno de trabajo. Este proceso se puede definir mediante los seis pasos básicos siguientes:

1. Definir el problema
2. Preparar los datos
3. Explorar los datos
4. Generar modelos
5. Explorar y validar los modelos
6. Implementar y actualizar los modelos




Figura 2.1 Relaciones entre los pasos del proceso

El proceso que se ilustra en la Figura 2.1, el diagrama es cíclico, lo que significa que la creación de un modelo de minería de datos es un proceso dinámico e iterativo. Una vez que ha explorado los datos, puede que descubra que resultan insuficientes para crear los modelos de minería de datos adecuados y que, por tanto, debe buscar más datos. O bien, puede generar varios modelos y descubrir entonces que no responden adecuadamente al problema planteado cuando los definió y que, por tanto, debe volver a definir el problema. Es posible que deba actualizar los modelos una vez implementados debido a que haya más datos disponibles. Puede que haya que repetir cada paso del proceso muchas veces para crear un modelo adecuado.

2.1 Herramientas

De esta forma han aparecido diferentes herramientas de negocio para la toma de decisiones DSS o Decision Support Systems, que coexisten: EIS, OLAP, consultas e informes y las propias herramientas de minería de datos.

2.1.2 EIS (Executive Information System): proporciona a los directivos acceso a la información de estado sus actividades de gestión. Informa rápidamente sobre cambios. La información solicitada puede ser en gran medida numérica (ventas semanales, nivel de stocks, balances parciales, etc) y es representada en forma gráfica al estilo de las hojas de cálculo.

2.1.3 OLAP (On-Line Analytical Processing): son más genéricas, funcionan sobre un sistema de información (transaccional o almacén de datos) y permiten realizar combinaciones de datos mucho más complejas y ambiciosas, con objetivos de análisis más estratégicos. En general están basadas en sistemas o interfaces multidimensionales que brindan la información de una manera matricial. Permiten facilidades para “manejar” y “transformar” datos, producen “otros” y son muy eficientes en el análisis ya que producen diferentes vistas de los mismos datos.

2.1.4 Sistema de Informes o consultas avanzadas: se basan en sistemas relacionales u objeto-relacionales y el resultado se brinda en forma tabular.

2.1.5 Herramientas de minería de datos: permiten extraer patrones, tendencias y regularidades para describir, comprender mejor los datos y para predecir comportamientos futuros. La Minería de Datos analiza los datos y el resto de las herramientas facilitan el acceso a la información para que el análisis sea más efectivo, es decir, son instrumentos de apoyo.

Además, debe contarse con almacenes de datos (Data WareHouse), siendo el sistema de información central en todo proceso. Un almacén de datos es una colección de datos orientada a un dominio, integrada, no volátil y variante en el tiempo para ayudar en la toma de decisiones. Un almacén es un conjunto de datos históricos, internos o externos descriptivos de un contexto. Que permiten aplicar eficientemente herramientas para resumir, describir y analizar datos con el fin de la toma estratégica de decisiones.

Las fuentes internas y externas están separadas. El origen de datos internos proviene de una base de datos transaccional. Pero también existen otras fuentes externas de información.

Un sistema especializado, llamado ETL (Extraction, Transformation, Load) se encarga de la carga y mantenimiento del almacén de datos. Realiza lectura de datos transaccionales, incorporación de datos externos, creación de claves, integración, limpieza, transformación, creación, mantenimiento de metadatos, planificación de cargas, indización, pruebas de calidad, etc.

En la figura 2.2 se ordenan los conceptos expuestos en los párrafos anteriores.




Figura 2.2 Introducción a la Minería de Datos – Orallo, Quintana y Ramirez

No obstante hay que tener en claro que los almacenes de datos no son imprescindibles para hacer extracción de conocimiento a partir de los datos. Se puede hacer minería de datos sobre un simple fichero de datos. Pero las ventajas de organizar un almacén de datos para realizar minería de datos de amortizan a medio y largo plazo cuando tenemos grandes volúmenes de datos, o estos aumentan con el tiempo.

3. El proceso de extracción del conocimiento (KDD)

La Extracción de conocimiento está principalmente relacionado con el proceso de descubrimiento conocido como Knowledge Discovery in Databases (KDD), que se refiere al proceso no-trivial de descubrir conocimiento e información potencialmente útil dentro de los datos contenidos en algún repositorio de información. No es un proceso automático, es un proceso iterativo que exhaustivamente explora volúmenes muy grandes de datos para determinar relaciones.

La minería de datos no es más que una fase del KDD, que integra los métodos de aprendizaje y estadísticos para obtener hipótesis de PATRONES y MODELOS.

KDD es un proceso que extrae información de calidad que puede usarse para dibujar conclusiones basadas en relaciones o modelos dentro de los datos. La figura 3.1 ilustra las etapas del proceso KDD:




Figura 3.1 Etapas del Proceso KDD

El KDD comienza con la RECOPIACIÓN E INTEGRACIÓN DE LA INFORMACIÓN a partir de unos datos iniciales de que se dispone (fase de selección de datos). Las primeras fases del KDD determinan que las fases sucesivas sean capaces de extraer conocimiento valido y útil a partir de la información original. Frecuentemente, la información que se quiere investigar sobre un cierto dominio de la organización se encuentra en bases de datos (Database) y otras fuentes muy diversas, tanto internas como externas (en general la información se encuentra ordenada en almacenes de datos). La disponibilidad de grandes

volúmenes de información en esta fase nos lleva a la necesidad de usar técnicas de muestreo para la selección de datos.

La fase siguiente del KDD integra la EXPLORACIÓN, la LIMPIEZA o criba de datos (Data Cleaning) y la TRANSFORMACION de datos. Se debe eliminar el mayor número posible de datos erróneos o inconsistentes (limpieza) e irrelevante (criba). En esta fase se utilizan herramientas de consulta (Query tools) y herramientas estadísticas (Statistics tools) casi exclusivamente. En la exploración se usan técnicas de análisis exploratorio de datos como los histogramas y los diagramas de caja, tallo y hojas, que ayudan a detectar datos anómalos o atípicos (outliers). La presencia de datos atípicos y valores desaparecidos (datos missing) puede llevarnos a usar algoritmos robustos a datos atípicos y desaparecidos, a filtrar la información, a reemplazar valores mediante técnicas d imputación y a transformar datos continuos en discretos mediante técnicas de discretización. Entre las técnicas avanzadas de transformación tenemos las de reducción y aumento de la dimensión.

La fase siguiente en el KDD es la propia minería de datos que se llevara a cabo a partir del desarrollo de modelos predictivos y descriptivos (Model Development) y mediante el análisis de datos (Data Analysis). Una vez recogidos los datos de interés, un explorador puede decidir qué tipo de patrón quiere descubrir. El tipo de conocimiento que se desea extraer va a marcar claramente la técnica de minería de datos a utilizar.

Para seleccionar y validar los modelos anteriores es necesaria una nueva fase consistente en el uso de criterios de evaluación de hipótesis. El despliegue del modelo a veces es trivial pero otras veces requiere un proceso de implementación o interpretación.

Una fase posterior del KDD es la relativa a la difusión y uso del conocimiento derivado de las técnicas de minería de datos a través de los modelos correspondientes que habitualmente desembocan en la generación de resultados (output Generation). El modelo puede tener muchos usuarios y necesitar difusión, con lo que puede requerir ser expresado de una manera comprensible para ser distribuido en la organización. En esta fase se utilizan herramientas de visualización (Visualization tools), presentación (Presentation tools) y transformación de datos (Data Transformation tools).

Por lo tanto, observamos que en el proceso de extracción del conocimiento KDD la secuencia de fases siguiente: SELECCIÓN-> EXPLORACIÓN -> LIMPIEZA-> TRANSFORMACIÓN -> MINERÍA DE DATOS-> EVALUACIÓN -> DIFUSIÓN.

En la fase de selección se integran y recopilan los datos, se determinan las fuentes de información que pueden ser útiles y donde conseguirlas, se identifican y seleccionan las variables relevantes en los datos y aplican las técnicas de muestreo adecuadas. Todo ello

se facilita disponiendo de un almacén de datos con la información en formato común y sin inconsistencias. Dado que los datos provienen de diferentes fuentes, es necesaria su **exploración** mediante técnicas de análisis exploratorio de datos, buscando entre otras cosas la distribución de los datos, su simetría y normalidad y las correlaciones existentes en la información. A continuación, es necesaria la **limpieza** de los datos, ya que pueden contener valores atípicos, valores faltantes y valores erróneos. En esta fase se analiza la influencia de datos atípicos, se imputan los valores faltantes y se eliminan o corrigen los datos incorrectos. A continuación, si es necesario, se lleva a cabo la **transformación** de los datos, generalmente mediante técnicas de reducción o aumento de la dimensión y escalado simple y multidimensional, entre otras. Las cuatro primeras fases se suelen englobar bajo el nombre de preparación de datos. En la **fase de minería de datos**, se decide cual es la tarea a realizar (clasificar, agrupar, etc.) y se elige la técnica a utilizar. En la **fase de evaluación e interpretación** se evalúan los patrones y se analizan por los expertos, y si es necesario se vuelve a las fases anteriores para una nueva iteración. Finalmente, en la **fase de difusión** se hace uso del nuevo conocimiento y se hace partícipe de el a todos los posibles usuarios.

4. Técnicas de minería de datos

La clasificación inicial de las técnicas de minería de datos distingue entre **técnicas predictivas**, en las que las variables pueden clasificarse inicialmente en dependientes e independientes, **técnicas descriptivas**, en las que todas las variables tienen inicialmente el mismo estatus y **técnicas auxiliares**.

Las **técnicas predictivas** especifican el modelo para los datos en base a un conocimiento teórico previo. El modelo supuesto para los datos debe contrastarse después del proceso de minería de datos antes de aceptarlo como válido. Formalmente, la aplicación de todo modelo debe superar las fases de *identificación objetiva* (a partir de los datos se aplican reglas que permitan identificar el mejor modelo posible que ajuste los datos), *estimación* (proceso de cálculo de los parámetros del modelo elegido para los datos en la fase de identificación), *diagnosis* (proceso de contraste de la validez del modelo estimado) y *predicción* (proceso de utilización del modelo identificado, estimado y validado para predecir valores futuros de las variables dependientes).

Podemos incluir entre estas técnicas todos los tipos de regresión, series temporales, análisis de la varianza y covarianza, análisis discriminante, árboles de decisión, redes neuronales, algoritmos genéticos y técnicas bayesianas. Tanto los árboles de decisión, como las redes neuronales y el análisis discriminante son a su vez *técnicas de clasificación* que pueden extraer perfiles de comportamiento o clases, siendo el objetivo construir un modelo que permita clasificar cualquier nuevo dato.

En las **técnicas descriptivas** no se asigna ningún papel predeterminado a las variables. No se supone la existencia de variables dependientes ni independientes y tampoco se supone la existencia de un modelo previo para los datos. Los modelos se crean automáticamente partiendo del reconocimiento de patrones. En este grupo se incluyen las técnicas de clustering y segmentación (que también son técnicas de clasificación en cierto modo), las técnicas de asociación y dependencia, las técnicas de análisis exploratorio de datos y las técnicas de reducción de la dimensión (factorial, componentes principales, correspondencias, etc.) y de escalamiento multidimensional.

Las **técnicas auxiliares** son herramientas de apoyo más superficiales y limitadas. Se trata de nuevos métodos basados en técnicas estadísticas descriptivas, consultas e informes y enfocados en general hacia la *verificación*.

A continuación, se muestra una clasificación de las técnicas de Data Mining.




Figura 4.1 Clasificación Técnicas Minería de Datos

Las técnicas de clasificación pueden pertenecer tanto al grupo de técnicas predictivas (discriminante, árboles de decisión y redes neuronales) como a las descriptivas (clustering y segmentación). Las técnicas de clasificación predictivas suelen denominarse técnicas de clasificación ad hoc y que clasifican individuos u observaciones dentro de grupos previamente definidos. Las técnicas de clasificación descriptivas se denominan técnicas de clasificación post hoc porque realizan clasificación sin especificación previa de los grupos.

En la figura 4.2 se muestra un diagrama con la clasificación de las técnicas de minería de datos




Figura 4.2 Diagrama de Clasificación

4.1 Técnicas predictivas

4.1.1 Regresión: Se usa una regresión para predecir los valores ausentes de una variable basándose en su relación con otras variables de la tabla de datos. Hay regresión lineal, no lineal, logística, logarítmica, univariada, multivariada, entre otras. Es la más utilizada para formar relaciones entre datos. Rápida y eficaz pero insuficiente en espacios multidimensionales donde puedan relacionarse más de dos variables.

4.1.2 Análisis de la varianza (Anova)

El análisis de varianza sirve para comparar si los valores de un conjunto de datos numéricos son significativamente distintos a los valores de otro o más conjuntos de datos. Se utiliza para analizar la relación entre una variable dependiente métrica y varias variables independientes no métricas. El objetivo es determinar si diversas muestras proceden de poblaciones con igual media. Los valores no métricos de las variables independientes determinarán una serie de grupos en la variable dependiente.

4.1.3 Series Temporales

Una serie temporal consiste en una colección de observaciones realizadas de manera secuencial en el tiempo. Una serie de tiempo es considerada continua cuando las observaciones son hechas de forma continua en el tiempo. Si las observaciones tienen lugar solo en momentos específicos entonces es considerada como una serie temporal discreta.

Existen múltiples objetivos que motivan el análisis de series temporales y están enfocados principalmente tanto a la extracción de información representativa como a la posibilidad predecir su comportamiento futuro. El más importante es el *descubrimiento de patrones*, que es la tarea no trivial de descubrir patrones interesantes en una serie de tiempo.

4.1.4 Métodos Bayesianos

Una red bayesiana es un grafo a cíclico dirigido en el que cada nodo representa una variable y cada arco una dependencia probabilística, en la cual se especifica la probabilidad condicional de cada variable dados sus padres. La variable a la que apunta el arco es dependiente (causa-efecto) de la que está en el origen de éste. La topología o estructura de la red nos da información sobre las dependencias probabilísticas entre las variables, pero también sobre las independencias condicionales de una variable (o conjunto de variables) dada otra variable(s). El obtener una red bayesiana a partir de datos, es un proceso de aprendizaje que se divide en dos etapas: el aprendizaje estructural y el aprendizaje paramétrico [Pearl, 1988]. La primera de ellas consiste en obtener la estructura de la red bayesiana, es decir, las relaciones de dependencia e independencia entre las variables involucradas. La segunda etapa, tiene como finalidad obtener las probabilidades a priori y condicionales requeridas a partir de una estructura dada.

4.1.5 Algoritmos Genéticos

Los AG utilizan una analogía del comportamiento natural observado en la biología. Se trabaja con una población de "individuos", en donde cada uno representa una solución potencial a un problema dado. A cada uno de los individuos se les asigna un "valor de aptitud", de acuerdo a qué tan buena sea su solución al problema. Luego los individuos con aptitudes más altas son seleccionados para replicarse, mutarse o "cruzarse" con otros individuos de la población. Esto produce nuevos individuos, los cuales comparten algunas características de cada uno de sus padres. Una nueva población de posibles soluciones es producida seleccionando los mejores individuos de la actual generación. El proceso se repite hasta satisfacer unos criterios de terminación.

4.1.6 Clasificación de ad hoc

4.1.6.1 Discriminante

El análisis discriminante es una técnica estadística multivariante cuya finalidad es describir (si existen) las diferencias entre grupos de objetos sobre los que se observan determinadas variables (variables discriminantes).

Los dos principales usos del análisis discriminante son la clasificación de objetos en grupos preestablecidos y la identificación de variables descriptivas que mejor definan la pertenencia a grupos.

4.1.6.2 Árboles de decisión

Un Árbol de decisión es un conjunto de condiciones organizadas en una estructura jerárquica. La decisión final depende del camino que se toma desde la raíz del árbol. Las opciones posibles a partir de una condición son excluyentes, es decir, en todo momento se llegará a una sola decisión.

Los árboles de decisión permiten clasificar los datos en grupos basados en los valores de las variables. El mecanismo consiste en elegir un atributo como raíz y desarrollar el árbol según las variables más significativas.

4.1.6.3 Redes Neuronales

El objetivo que da origen a las **Redes Neuronales**, es construir un modelo que sea capaz de reproducir el método de aprendizaje del cerebro humano. Las células encargadas de este aprendizaje son las **neuronas** interconectadas entre sí a través de complejas redes.

Son capaces de extraer patrones y detectar tramas que son muy difíciles de apreciar por el ser humano u otras técnicas computacionales, siendo la facilidad de implementación de estos métodos lo que ha facilitado su popularidad. Estas RNA se caracterizan por tres partes fundamentales: la topología de la red (propagación hacia adelante o recurrentes), la regla de aprendizaje (supervisado, no supervisado, reforzado, etc...) y el tipo de entrenamiento.

4.2 Técnicas Descriptivas

4.2.1 Reglas de asociación

Este tipo de técnicas se emplea para establecer las posibles relaciones o correlaciones entre distintas acciones o sucesos aparentemente independientes; pudiendo reconocer como la ocurrencia de un suceso o acción puede inducir o generar la aparición de otros. Son

utilizadas cuando el objetivo es realizar análisis exploratorios, buscando relaciones dentro del conjunto de datos.

4.2.2 Análisis exploratorio

El Análisis Exploratorio de Datos (E.D.A.: Exploratory data analysis) es un conjunto de técnicas estadísticas cuya finalidad es conseguir un entendimiento básico de los datos y de las relaciones existentes entre las variables analizadas. Para conseguir este objetivo el E.D.A. proporciona métodos sistemáticos sencillos para organizar y preparar los datos, detectar fallos en el diseño y recogida de los mismos, tratamiento y evaluación de datos ausentes (missing) e identificación de casos atípicos (outliers).

4.2.3 Reducción de dimensión

Si es posible describir con precisión valores de p variables por un pequeño subconjunto $r < p$ de ellas, se habrá reducido la dimensión del problema a costa de una pequeña pérdida de información. Éste es el principal objetivo de la técnica y fue desarrollado por Hotelling (1933), aunque sus orígenes se encuentran en los ajustes ortogonales por mínimos cuadrados introducidos por K. Pearson (1901).

4.2.4 Clasificación post hoc

4.2.4.1 Clustering

Las técnicas de Clustering son las que utilizando algoritmos matemáticos se encargan de agrupar objetos. Usando la información que brindan las variables que pertenecen a cada objeto se mide la similitud entre los mismos, y una vez hecho esto se colocan en clases que son muy similares internamente (entre los miembros de la misma clase) y a la vez diferente entre los miembros de las diferentes clases.

4.2.4.2 Segmentación

La segmentación puede definirse como el proceso de dividir un todo (población, consumidores, etc.) en grupos uniformes más pequeños que tengan características semejantes denominados segmentos. La segmentación suele realizarse según los valores de determinadas variables que son los que fijan sus características.

4.3 Técnicas auxiliares

El Proceso Analítico de Transacciones (OLAP) es parte de una gama de herramientas de toma de decisiones. Las consultas tradicionales y los reportes describen lo que hay en la base de datos. OLAP va más allá, es usado para responder porque ciertas cosas son ciertas. Un analista genera una serie de patrones y relaciones hipotéticas usando consultas (mediante herramientas como SQL) para aprobarlos o rechazarlos. OLAP es en esencia un proceso deductivo.

Pero, ¿qué pasa cuando el número de variables por analizar es por docenas o incluso cientos? Se vuelve más difícil el encontrar una buena hipótesis, analizar la base de datos con OLAP, verificarla o desaprobala.

La minería de datos es diferente de OLAP porque en lugar de verificar patrones hipotéticos, usa los mismos datos para descubrir tales patrones. Es en esencia un proceso inductivo.

5. Sistema de minería de datos

La figura 5.1 muestra los sistemas de minerías de datos más utilizados en el mercado junto con las técnicas que tratan cada uno de ellos, las plataformas sobre las que trabajan y las interfaces de lectura de datos.

Producto	Compañía	Técnicas	Plataforma	Interfaz
Knowledge Seeker	Angoss	Árboles de Decisión	Win	ODBC
CART	Salford Systems	Árboles de Decisión	Win/UNIX	
Clementine	SPSS	Amplio abanico	Win/UNIX	ODBC
Data Surveyor	Data Distilleries	Amplio abanico	UNIX	ODBC
Gain Smarts	Urban Science	Gráficos-Ganancias	Win/UNIX	
Intelligent Miner	IBM	Amplio abanico	UNIX (AIX)	IBM, DB2
Micostrategy	Micostrategy	Datawarehouse	Win	Oracle
Polyanalyst	Megaputer	Simbólicas	Win	Oracle, ODBC
Darwin	Oracle	Amplio abanico	Win/UNIX	Oracle
Enterprise Miner	SAS Institute	Amplio abanico	Win/UNIX/Mac	
SIG MineSet	Silicon Graphics	Asociación y Clasificación	UNIX	Oracle, Sybase, Informix
Wizsoft/Wizwhy	Wizsoft			

Figura 5.1 Sistemas de Minería de Datos mas usados

Los Sistemas de minería de datos que veremos son SPSS Clementine y SAS Enterprise Miner.

SPSS Clementine es un sistema de minería de datos que contempla diferentes fuentes de datos (ASCII, Oracle, Informix, Sybase, Ingres, etc), interfaz visual sencilla y distintas herramientas de minería de datos (redes neuronales, árboles de decisión, regresión, series temporales, cluster, etc). Trabaja bajo los Sistemas operativos Unix y Windows.

SAS Enterprise Miner es una herramienta completa que incluye conexión a bases de datos (a través de ODBC y SAS datasets), muestreo e inclusión de variables derivadas, partición de la evaluación del modelo respecto a conjuntos de entrenamiento, validación y chequeo, distintas herramientas de minería de datos (algoritmos y tipos de árboles de decisión, redes neuronales, regresión y clustering, etc.), comparación de modelos y conversión de los modelos en código SAS. Dispone de un interfaz gráfico muy sencillo e incluye herramientas para flujo de proceso, tratando el proceso KDD como un proceso y las fases se pueden repetir, modificar y grabar.

Existen en el mercado otros sistemas que permiten realizar Data Mining a través de bases de datos. Concretamente, las bases de datos Oracle y SQL Server disponen de sistemas de minerías de datos asociados.

Oracles dispone de herramientas de "Business Intelligence" y "Data Mining" que tienen una orientación más empresarial y de sistemas de información. También dispone de

herramientas de OLAP, Datawarehouse e informes Avanzados. Asimismo, presenta herramientas propias de minería de datos a través del producto Oracle Darwin.

Microsoft SQL Server dispone del producto Analysis Services que implementa la minería de datos. Se fundamenta en el “OLE DB for Data Mining” e implementa una extensión del SQL que trabaja con DMM (Data Mining Model) que permite crear el modelo, entrenarlo y realizar predicciones. La versión SQL Server 2005, en su modulo Analysis Services cuenta con los algoritmos de minería de datos más avanzados entre los que se incluyen arboles de decisión y regresión, series temporales, agrupación clústeres, reglas de asociación, algoritmo Naive Bayes y minería de textos. Dispone de un asistente y diseñador para minería de datos que permite construir modelos sofisticados a través de una interfaz fácil de usar. Además, se proporcionan gráficos de elevación y beneficios, por lo que podrá comparar y contrastar la calidad de los modelos antes de dedicarse a la distribución.

La selección de una otra **herramienta de minería de datos** habrá de hacerse previa evaluación de sus características. Entre las más importantes a tener en cuenta, destacan las siguientes:

1. Tipos de datos: no todos los datos son iguales y, en el mercado, no todas las herramientas están preparadas para ellos, por eso, hay que comprobar con qué formato exacto puede trabajar el sistema de minería de datos escogido. Entre los ejemplos más extendidos se encuentran el texto con formato, los datos basados en registros y los datos relacionales.

2. Compatibilidad entre sistemas: la herramienta de **minería de datos** deberá interactuar con los sistemas operativos existentes, por lo que habrá que tener esto en cuenta. En ocasiones, la compatibilidad se reduce a una opción, mientras que hay casos en que se extiende a varios sistemas. Por último, es necesario saber que también existen sistemas de minería de datos que proporcionan interfaces de usuario basadas en web y permiten el uso de datos XML como entrada.

3. Fuentes de datos: cuanto más versátiles sean las **capacidades de minería de datos** aplicables a la obtención de información de orígenes diversos más interesa. Si estas opciones están limitadas no se puede hacer frente a la heterogeneidad de fuentes, algo muy común en este tipo de procesos.

4. Funciones y metodologías: hay algunos sistemas de minería de datos que proporcionan una única función, como puede ser la clasificación, mientras que otros proporcionan múltiples funciones, tales como la descripción, análisis OLAP, descubrimiento, análisis estadístico, clasificación, predicción, agrupamiento o búsqueda de similitudes. No hace falta

escoger el que más funciones tiene, sino el que tiene todas las funciones que se van a necesitar.

5. Acoplamiento con bases de datos o sistemas de almacenamiento de datos: los sistemas de **minería** de datos deben complementarse con los sistemas de almacenamiento de datos o de base de datos. Los componentes acoplados se integran en un entorno de procesamiento de información uniforme. Este acoplamiento puede producirse de distintas formas, como las que se indican a continuación:

- Sin acoplamiento.
- Acoplamiento débil.
- Acoplamiento semi - estanco.
- Acoplamiento estanco.

6. Escalabilidad: esta cualidad puede evaluarse desde dos perspectivas diferentes:

- **Escalabilidad de fila (tamaño de base de datos):** el sistema de minería de datos se considera escalable cuando el número de filas se amplía en una determinada proporción y el sistema no tarda más tiempo del estimado (incrementado proporcionalmente) en ejecutar la consulta.
- **Escalabilidad de columna (dimensión):** el sistema de minería de datos se considera escalable si el tiempo de ejecución de consulta aumenta linealmente a la vez que lo hace el número de columnas.

7. Herramientas de visualización: la selección de la solución de **minería de datos** debe tener en cuenta la visibilidad que ofrecerá, que puede determinarse en función de los datos y los resultados o mostrar todo el proceso.

8. Interfaz gráfica de usuario: por último, hay que valorar la capacidad de interacción que la solución permite y la sencillez de su manejo.

6. Conclusión

La minería de datos surge a partir de la necesidad de analizar grandes volúmenes de datos, con el objetivo de obtener modelos y patrones descriptivos o predictivos, siendo esta una parte de lo que se conoce como KDD: descubrimiento de conocimiento a partir de base de datos.

La Minería de Datos ha sufrido transformaciones en los últimos años de acuerdo con cambios tecnológicos, de estrategias de marketing, la extensión de los modelos de compra en línea, etc. Los más importantes de ellos son:

La importancia que han cobrado los **datos no estructurados** (texto, páginas de Internet, etc.).

La necesidad de integrar los algoritmos y resultados obtenidos en sistemas operacionales, portales de Internet, etc.

La exigencia de que los procesos funcionen prácticamente *en línea* (por ejemplo, en casos de fraude con una tarjeta de crédito).

Los **tiempos de respuesta**. El gran volumen de datos que hay que procesar en muchos casos para obtener un modelo válido es un inconveniente; esto implica grandes cantidades de tiempo de proceso y hay problemas que requieren una respuesta en tiempo real.

Por lo que estas tendencias nos guían hacia donde debemos enfocar las investigaciones tanto a nivel académico como comercial.

El procesamiento y análisis de las grandes cantidades de datos que se producen en la actualidad, posibilitan el hallazgo de patrones y tendencias ocultos en los mismos, que impacta directamente en la toma de decisiones en diversas áreas de estudios. Se generan datos a gran velocidad y en grandes cantidades que requieren ser procesados para poder actuar de manera rápida.

Para finalizar debemos mencionar que la importancia de la actividad de minería de datos y herramientas tradicionales, asumen que los datos que se usarán para construir los modelos contienen la información necesaria para lograr el propósito buscado: obtener suficiente conocimiento que pueda ser aplicado al *negocio* (o problema) para obtener un beneficio (o solución).

7. Referencias

A. Libros

- Minería de datos: técnicas y herramientas. PEREZ LOPEZ, CESAR, SANTIN GONZALEZ, DANIEL. - Editorial Paraninfo
- Introducción a la minería de datos: José Hernández Orallo, María José Ramírez Quintana, César Ferri Ramírez – Editor Pearson Educación, 2004 – ISBN 8420540919

B. Apuntes de clase

- http://exa.unne.edu.ar/depar/areas/informatica/dad/BDII/Presentaciones_Proyector/Mineria_de_Datos_Introduccion.pdf
- http://exa.unne.edu.ar/depar/areas/informatica/dad/BDII/Presentaciones_Proyector/Mineria_de_Datos_Tecnicas_Predictivas_de_Modelizacion.pdf