



Universidad Nacional del Nordeste



Facultad de Ciencias Exactas y Naturales y Agrimensura

Carrera: Licenciatura en Sistemas de Información

Asignatura: Base de Datos II

Grupo: 13

Tema: Redes Neuronales

Alumnos:

✓ Billordo, Tania Iliana – L.U: 45.971

✓ Dominguez, Cecilia Beatriz – L.U: 46.686

✓ Ferrari, Analía Rocio – L.U: 49.987

✓ Ibarra, Rocio Celeste – L.U: 43.374

✓ Navarro, Nicolás – L.U: 42.340

Contenido

1.	Introducción.....	3
2.	MINERIA DE DATOS.....	4
3.	TÉCNICAS EN MINERÍA DE DATOS.....	4
3.1	Técnicas predictivas.....	4
3.2	Técnicas Descriptivas.....	5
3.3	Técnicas Auxiliares	6
4.	Descripción de una Red Neuronal.....	6
5.	Ventajas que ofrecen las redes neuronales.....	8
6.	Elementos básicos que componen una red neuronal.....	8
6.1	Función de entrada (input function).....	9
6.2	Función de activación o de transferencia (activation function)	10
6.3	Función de salida (output function)	10
7.	Funcionamiento de una Red Neuronal	11
8.	Mecanismos de aprendizaje	11
8.1	Aprendizaje supervisado	12
8.1.1	Aprendizaje por corrección de error	12
8.1.2	Aprendizaje por refuerzo	13
8.1.3	Aprendizaje estocástico.....	13
8.2	Aprendizaje no supervisado.....	13
8.2.1	Aprendizaje hebbiano.....	14
8.2.2	Aprendizaje competitivo y comparativo.....	14
9.	Topologías principales.....	15
9.1	Topología de las redes neuronales.....	15
9.2	Redes monocapa.....	15
9.3	Redes multicapa.....	15
9.4	Conexión entre neuronas	17
9.5	Redes de propagación hacia atrás (backpropagation)	17
9.6	Estructura de la Red Hopfield.	17
10.	Aplicaciones de las Redes Neuronales	18
10.1	Asociación y clasificación.....	18
10.2	Regeneración de patrones.....	19
10.3	Regeneración y generalización	19
10.4	Optimización	19
11.	Conclusión.....	20

Tabla de Ilustraciones

Figura 1: Ejemplo de una red neuronal totalmente conectada[3]	7
Figura 2: Comparación entre una neurona biológica (izquierda) y una artificial (derecha)[1]	9
Figura 3: Aprendizaje Supervisado [5]	12
Figura 4:Aprendizaje No Supervisado[5]	14
Figura 5: Red Neuronal Monocapa[6]	15
Figura 6: Red Neuronal Multicapa (feedforwad)[6].....	16
Figura 7:Red Neuronal Multicapa (feedback)[6].....	16

1. Introducción

Las redes neuronales son más que otra forma de emular ciertas características propias de los humanos, como la capacidad de memorizar y de asociar hechos. Si se examinan con atención aquellos problemas que no pueden expresarse a través de un algoritmo, se observará que todos ellos tienen una característica en común: la experiencia. El hombre es capaz de resolver estas situaciones acudiendo a la experiencia acumulada. Así, parece claro que una forma de aproximarse al problema consista en la construcción de sistemas que sean capaces de reproducir esta característica humana.

En definitiva, las redes neuronales no son más que un modelo artificial y simplificado del cerebro humano, que es el ejemplo más perfecto del que disponemos para un sistema que es capaz de adquirir conocimiento a través de la experiencia.

Una red neuronal es “un nuevo sistema para el tratamiento de la información, cuya unidad básica de procesamiento está inspirada en la célula fundamental del sistema nervioso humano: la neurona”.

Por lo tanto, las Redes Neuronales:

- Consisten de unidades de procesamiento que intercambian datos o información.

- Se utilizan para reconocer patrones, incluyendo imágenes, manuscritos y secuencias de tiempo (por ejemplo: tendencias financieras).
- Tienen capacidad de aprender y mejorar su funcionamiento. [1]

2. MINERIA DE DATOS

La Minería de Datos es el proceso de extraer información no trivial y potencialmente útil a partir de **grandes conjuntos de datos** disponibles en las ciencias experimentales (registros históricos de observaciones, re análisis, simulaciones, etc.), proporcionando información en un **formato legible** que puede ser usada para resolver problemas de **diagnosis, clasificación o predicción**.

Tradicionalmente, este tipo de problemas se resolvían de forma **manual** aplicando **técnicas estadísticas clásicas**, pero el incremento del volumen de los datos ha motivado el estudio de técnicas de análisis automáticas que usan herramientas más complejas.

Por lo tanto, la Minería de datos **identifica tendencias en los datos** que van más allá de un análisis simple. Técnicas modernas de Minería de datos (Ej.: árboles de decisión, algoritmos de regresión, redes neuronales, redes bayesianas, etc.) se utilizan en ámbitos muy diferentes para resolver problemas de **asociación, clasificación, segmentación y predicción**. [2]

3. TÉCNICAS EN MINERÍA DE DATOS

La **clasificación** inicial de las técnicas de minería de datos distingue entre **técnicas predictivas**, en las que las variables pueden clasificarse inicialmente en dependientes e independientes, **técnicas descriptivas**, en las que todas las variables tienen inicialmente el mismo estatus y **técnicas auxiliares**.

3.1 Técnicas predictivas

- Regresión: se utiliza para predecir los valores ausentes de una variable basándose en su relación con otras variables de la tabla de datos.
- Análisis de la Varianza (ANOVA): sirve para comparar si los valores de un conjunto de datos numéricos son significativamente distintos a los valores de otro o más conjuntos de datos.

- Series temporales: consiste en una colección de observaciones realizadas de manera secuencial en el tiempo. Si las observaciones tienen lugar solo en momentos específicos entonces es considerada como una serie temporal discreta.
- Métodos bayesianos: grafo acíclico dirigido en el que cada nodo representa una variable y cada arco una dependencia probabilística, en la cual se especifica la probabilidad condicional de cada variable dados sus padres.
- Algoritmos genéticos: utilizan una analogía del comportamiento natural observado en la biología. Se trabaja con una población de "individuos", en donde cada uno representa una solución potencial a un problema dado. Luego los individuos con aptitudes más altas son seleccionados para replicarse, mutarse o "cruzarse" con otros individuos de la población. Esto produce nuevos individuos.

Clasificación ad hoc

- Discriminante: técnica estadística multivariante cuya finalidad es describir (si existen) las diferencias entre grupos de objetos sobre los que se observan determinadas variables (variables discriminantes).
- Árboles de decisión: es un conjunto de condiciones organizadas en una estructura jerárquica. La decisión final depende del camino que se toma desde la raíz del árbol.
- Redes Neuronales Artificiales: el objetivo de las RNA, es construir un modelo que sea capaz de reproducir el método de aprendizaje del cerebro humano. Son capaces de extraer patrones y detectar tramas que son muy difíciles de apreciar por el ser humano u otras técnicas computacionales.[3]

3.2 Técnicas Descriptivas

- Reglas de Asociación: Se emplean para establecer las posibles correlaciones entre distintas acciones o sucesos aparentemente independientes. El objetivo es realizar análisis exploratorios.
- Análisis exploratorio: Proporciona métodos sistemáticos sencillos para organizar y preparar los datos, detectar fallos en el diseño y recogida de los mismos, tratamiento y evaluación de datos ausentes (missing) e identificación de casos atípicos (outliers).

- Reducción de la dimensión: Si es posible describir con precisión valores de p variables por un pequeño subconjunto $r < p$ de ellas, se habrá reducido la dimensión del problema a costa de una pequeña pérdida de información.

Clasificación post hoc

- Clustering: Son las técnicas que utilizando algoritmos matemáticos se encargan de agrupar objetos. Usando la información que brindan las variables que pertenecen a cada objeto se mide la similitud entre los mismos.
- Segmentación: Puede definirse como el proceso de dividir un todo (población, consumidores, etc.) en grupos uniformes más pequeños que tengan características semejantes denominados segmentos. [3]

3.3 Técnicas Auxiliares

El **Proceso Analítico de Transacciones (OLAP)** es parte de una gama de herramientas de toma de decisiones. OLAP es en esencia un **proceso deductivo**.

Tiene especial relevancia cuando el número de variables por analizar es por docenas o incluso cientos, se vuelve más difícil el encontrar una buena **hipótesis** manualmente, resulta entonces apropiado analizar la base de datos con OLAP para verificarla o desaprobirla.

La **minería de datos es diferente de OLAP** porque en lugar de verificar **patrones hipotéticos**, usa los mismos datos para descubrir tales patrones. Es en esencia un **proceso inductivo**. [3]

4. Descripción de una Red Neuronal

Podemos definir una red neuronal como un conjunto de elementos de procesamiento de la información altamente interconectados, que son capaces de aprender con la información que se les alimenta. La principal característica de esta nueva tecnología de redes neuronales es que puede aplicarse a un gran número de problemas de pueden ir desde problemas complejos reales a modelos teóricos sofisticados como por ejemplo reconocimiento de imágenes, reconocimiento de voz, análisis y filtrado de señales, clasificación, discriminación, análisis financiero, predicción dinámica, etc.

Las Redes Neuronales tratan de emular el sistema nervioso, de forma que son capaces de reproducir alguna de las principales tareas que desarrolla el cerebro humano. No

obstante, debemos insistir en el hecho de que los Sistemas Neuronales Artificiales, como cualquier otra herramienta construida por el hombre, tienen limitaciones y solo poseen un parecido superficial con sus contrapartidas biológicas. Las redes neuronales, en relación con el procesamiento de información, heredan tres características básicas de las redes de neuronas biológicas: paralelismo masivo, respuesta no lineal de las neuronas frente a las entradas recibidas y procesamiento de información a través de múltiples capas de neuronas.

Una de las principales propiedades de estos modelos es su capacidad de aprender y generalizar a partir de ejemplos reales. Es decir, la red aprende a reconocer la relación que existe entre el conjunto de entradas proporcionadas como ejemplos y sus correspondientes salidas, de modo que, finalizando el aprendizaje, cuando a la red se le presenta una nueva entrada (aunque este incompleta o posea algún error), en base a la relación funcional establecida en el mismo, es capaz de generalizarla ofreciendo una salida. En consecuencia, podemos definir una red neuronal artificial como un sistema inteligente capaz, no solo de aprender, sino también de generalizar.

Una red neuronal está formada por unidades de procesamiento que reciben el nombre de neuronas o nodos. Estos nodos están organizados en grupos que se llaman “capas”. Generalmente existen tres tipos de capas: una capa de entrada, una o varias capas ocultas y una capa de salida. Las conexiones se establecen entre los nodos de cada capa adyacentes. La capa de entrada mediante la cual se presentan los datos a la red, está formada por nodos de entrada que reciben la información directamente del exterior. La capa de salida representa la respuesta de la red a una entrada dada siendo esta información transferida al exterior. Las capas ocultas o intermedias se encargan de procesar la información y se interponen entre las capas de entrada y salida y son las únicas que no tienen conexión con el exterior.[3]




Figura 1: Ejemplo de una red neuronal totalmente conectada[3]

5. Ventajas que ofrecen las redes neuronales

Debido a su constitución y a sus fundamentos, las redes neuronales artificiales presentan un gran número de características semejantes a las del cerebro. Por ejemplo, son capaces de aprender de la experiencia, de generalizar de casos anteriores a nuevos casos, de abstraer características esenciales a partir de entradas que representan información irrelevante, etc. Esto hace que ofrezcan numerosas ventajas y que este tipo de tecnología se esté aplicando en múltiples áreas. Entre las ventajas se incluyen:

- **Aprendizaje Adaptativo:** Capacidad de aprender a realizar tareas basadas en un entrenamiento o en una experiencia inicial.
- **Auto-organización:** Una red neuronal puede crear su propia organización o representación de la información que recibe mediante una etapa de aprendizaje.
- **Tolerancia a fallos:** La destrucción parcial de una red conduce a una degradación de su estructura; sin embargo, algunas capacidades de la red se pueden retener, incluso sufriendo un gran daño.
- **Operación en tiempo real:** Los cálculos neuronales pueden ser realizados en paralelo; para esto se diseñan y fabrican máquinas con hardware especial para obtener esta capacidad.
- **Fácil inserción dentro de la tecnología existente:** Se pueden obtener chips especializados para redes neuronales que mejoran su capacidad en ciertas tareas. Ello facilitará la integración modular en los sistemas existentes. [1]

6. Elementos básicos que componen una red neuronal

Un esquema de una red neuronal está constituido por neuronas interconectadas y arregladas en tres capas (esto último puede variar). Los datos ingresan por medio de la “capa de entrada”, pasan a través de la “capa oculta” y salen por la “capa de salida”. Cabe mencionar que la capa oculta puede estar constituida por varias capas.

Antes de comenzar el estudio sobre las redes neuronales, se debe aprender algo sobre las neuronas y de cómo ellas son utilizadas por una red neuronal. Podemos observar en la Figura 1.2 la comparación entre una neurona biológica (izquierda) y una artificial (derecha).

Mientras una neurona es muy pequeña en sí misma, cuando se combinan cientos, miles o millones de ellas pueden resolver problemas muy complejos. Por ejemplo, el cerebro humano se compone de billones de tales neuronas.[1]




Figura 2: Comparación entre una neurona biológica (izquierda) y una artificial (derecha)[1]

6.1-Función de entrada (input function)

La neurona trata a muchos valores de entrada como si fueran uno solo; esto recibe el nombre de entrada global. Por lo tanto, ahora nos enfrentamos al problema de cómo se pueden combinar estas simples entradas ($ini_1, ini_2, \dots$) dentro de la entrada global, gin_i . Esto se logra a través de la función de entrada, la cual se calcula a partir del vector entrada. La función de entrada puede describirse como sigue:

$$\text{Input}_i = (in_{i1} \cdot w_{i1}) * (in_{i2} \cdot w_{i2}) * \dots (in_{in} \cdot w_{in})$$

dónde: * representa al operador apropiado (por ejemplo: máximo, sumatoria, productoria, etc.), n al número de entradas a la neurona N_i y w_i al peso.

Los valores de entrada se multiplican por los pesos anteriormente ingresados a la neurona. Por consiguiente, los pesos que generalmente no están restringidos cambian la medida de influencia que tienen los valores de entrada. Es decir, que permiten que un gran valor de entrada tenga solamente una pequeña influencia, si estos son lo suficientemente pequeños.

Algunas de las funciones de entrada más comúnmente utilizadas y conocidas son:

- **Sumatoria de las entradas pesadas:** es la suma de todos los valores de entrada a la neurona, multiplicados por sus correspondientes pesos.

$$\sum_j (n_{ij} w_{ij}), \text{ con } j = 1, 2, \dots, n$$

- **Productoria de las entradas pesadas:** es el producto de todos los valores de entrada a la neurona, multiplicados por sus correspondientes pesos.

$$\prod_j (n_{ij} w_{ij}), \text{ con } j = 1, 2, \dots, n$$

- **Máximo de las entradas pesadas:** solamente toma en consideración el valor de entrada más fuerte, previamente multiplicado por su peso correspondiente.

$$\text{Max}_j (n_{ij} w_{ij}), \text{ con } j = 1, 2, \dots, n \quad [1]$$

6.2 Función de activación o de transferencia (activation function)

Una neurona biológica puede estar activa (excitada) o inactiva (no excitada); es decir, que tiene un “estado de activación”. La función activación calcula el estado de actividad de una neurona; transformando la entrada global (menos el umbral, Θ_i) en un valor (estado) de activación, cuyo rango normalmente va de (0 a 1) o de (−1 a 1). Esto es así, porque una neurona puede estar totalmente inactiva (0 o −1) o activa (1).

Todas las entradas en un nodo son ponderadas, combinadas y procesadas a través de la función de activación que controla el flujo de salida de ese nodo para conectar con todos los nodos de la capa siguiente. Esta función de transferencia sirva para normalizar la salida.[1]

6.3 Función de salida (output function)

El último componente que una neurona necesita es la función de salida. El valor resultante de esta función es la salida de la neurona i (out_i); por ende, la función de salida determina qué valor se transfiere a las neuronas vinculadas. Si la función de activación está por debajo de un umbral determinado, ninguna salida se pasa a la neurona subsiguiente.

Normalmente, no cualquier valor es permitido como una entrada para una neurona, por lo tanto, los valores de salida están comprendidos en el rango $[0, 1]$ o $[-1, 1]$. También pueden ser binarios $\{0, 1\}$ o $\{-1, 1\}$.

Dos de las funciones de salida más comunes son:

- Ninguna: este es el tipo de función más sencillo, tal que la salida es la misma que la entrada. Es también llamada función identidad.

$$\bullet \text{ Binaria: } \begin{cases} 1 & \text{si } \text{act}_i \geq \xi_i \\ 0 & \text{si } \text{act}_i < \xi_i \end{cases}, \text{ donde } \xi_i \text{ es el umbral.}$$

7. Funcionamiento de una Red Neuronal

Para la creación y aplicación de una red neuronal a un problema concreto, hemos de distinguir los siguientes pasos:

- **Conceptualización del modelo para el estudio del problema concreto:** En este modelo debemos señalar las entradas, salidas y la información que se dispone.
- **Adecuación de la información de que se dispone a la estructura de la red a crear:** Es decir, se construirán los patrones de aprendizaje, parte de la información que va a ser utilizada para el entrenamiento o aprendizaje de la red y los patrones de validación, parte de la información que va a ser utilizada como validación de la red.
- **Fase de aprendizaje:** Se le va presentando a la red los patrones adecuados y la red va proporcionando una salida, este proceso se repite un cierto número de etapas, estas salidas se comparan con las salidas esperadas y los diversos algoritmos de aprendizaje intentan minimizar el error que hay entre la salida proporcionada por la red y la salida esperada.
- **Fase de validación:** Se presentan a la red entrenada el conjunto de patrones de validación, y se ve el error cometido por la red en este conjunto, este error es una medida de la bondad de la red.
- **Fase de generalización:** Si hemos conseguido una red adecuada se procede a utilizar la red como modelo predictor, aportándole una nueva entrada, la red la procesará y dará una salida.[4]

8. Mecanismos de aprendizaje

Un aspecto importante respecto al aprendizaje de las redes neuronales es el conocer cómo se modifican los valores de los pesos, es decir, cuáles son los criterios que se siguen para cambiar el valor asignado a las conexiones cuando se pretende que la red aprenda una nueva información.

Hay dos métodos de aprendizaje importantes que pueden distinguirse:

- Aprendizaje supervisado.
- Aprendizaje no supervisado.

8.1 Aprendizaje supervisado

El aprendizaje supervisado se caracteriza porque el proceso de aprendizaje se realiza mediante un entrenamiento controlado por un agente externo (supervisor, maestro) que determina la respuesta que debería generar la red a partir de una entrada determinada. El supervisor controla la salida de la red y en caso de que ésta no coincida con la deseada, se procederá a modificar los pesos de las conexiones, con el fin de conseguir que la salida obtenida se aproxime a la deseada.

En este tipo de aprendizaje se suelen considerar, a su vez, tres formas de llevarlo a cabo, que dan lugar a los siguientes aprendizajes supervisados:

- 1) Aprendizaje por corrección de error.
- 2) Aprendizaje por refuerzo.
- 3) Aprendizaje estocástico. [1]




Figura 3: Aprendizaje Supervisado [5]

8.1.1 Aprendizaje por corrección de error

Consiste en ajustar los pesos de las conexiones de la red en función de la diferencia entre los valores deseados y los obtenidos a la salida de la red, es decir, en función del error cometido en la salida. [1]

8.1.2 Aprendizaje por refuerzo

Se trata de un aprendizaje supervisado, más lento que el anterior, que se basa en la idea de no disponer de un ejemplo completo del comportamiento deseado, es decir, de no indicar durante el entrenamiento exactamente la salida que se desea que proporcione la red ante una determinada entrada.

En el aprendizaje por refuerzo la función del supervisor se reduce a indicar mediante una señal de refuerzo si la salida obtenida en la red se ajusta a la deseada (éxito = +1 o fracaso = -1), y en función de ello se ajustan los pesos basándose en un mecanismo de probabilidades.[1]

8.1.3 Aprendizaje estocástico

Consiste básicamente en realizar cambios aleatorios en los valores de los pesos de las conexiones de la red y evaluar su efecto a partir del objetivo deseado y de distribuciones de probabilidad. [1]

8.2 Aprendizaje no supervisado

Las redes con aprendizaje no supervisado (también conocido como autosupervisado) no requieren influencia externa para ajustar los pesos de las conexiones entre sus neuronas. La red no recibe ninguna información por parte del entorno que le indique si la salida generada en respuesta a una determinada entrada es o no correcta.

En cuanto a los algoritmos de aprendizaje no supervisado, en general se suelen considerar dos tipos, que dan lugar a los siguientes aprendizajes:

- Aprendizaje hebbiano.
- Aprendizaje competitivo y comparativo.[1]




Figura 4: Aprendizaje No Supervisado[5]

8.2.1 Aprendizaje hebbiano

Esta regla de aprendizaje es la base de muchas otras, la cual pretende medir la familiaridad o extraer características de los datos de entrada. El fundamento es una suposición bastante simple: si dos neuronas N_i y N_j toman el mismo estado simultáneamente (ambas activas o ambas inactivas), el peso de la conexión entre ambas se incrementa. [1]

8.2.2 Aprendizaje competitivo y comparativo

Se orienta a la clasificación de los datos de entrada. Como característica principal del aprendizaje competitivo se puede decir que, si un patrón nuevo se determina que pertenece a una clase reconocida previamente, entonces la inclusión de este nuevo patrón a esta clase matizará la representación de la misma. Si el patrón de entrada se determinó que no pertenece a ninguna de las clases reconocidas anteriormente, entonces la estructura y los pesos de la red neuronal serán ajustados para reconocer la nueva clase. [1]

9. Topologías principales

9.1 Topología de las redes neuronales

La topología o arquitectura de una red neuronal consiste en la organización y disposición de las neuronas en la misma, formando capas o agrupaciones de neuronas más o menos alejadas de la entrada y salida de dicha red. En este sentido, los parámetros fundamentales de la red son: el número de capas, el número de neuronas por capa, el grado de conectividad y el tipo de conexiones entre neuronas. [1]

9.2 Redes monocapa

En las redes monocapa, se establecen conexiones entre las neuronas que pertenecen a la única capa que constituye la red. Las redes monocapas se utilizan generalmente en tareas relacionadas con lo que se conoce como autoasociación (regenerar información de entrada que se presenta a la red de forma incompleta o distorsionada). [1]




Figura 5: Red Neuronal Monocapa[6]

9.3 Redes multicapa

Las redes multicapas son aquellas que disponen de un conjunto de neuronas agrupadas en varios (2, 3, etc.) niveles o capas. En estos casos, una forma para distinguir la capa a la que pertenece una neurona, consistiría en fijarse en el origen de las señales que recibe a la entrada y el destino de la señal de salida. Normalmente, todas las neuronas de una capa reciben señales de entrada desde otra capa anterior (la cual está más cerca a la entrada de

la red), y envían señales de salida a una capa posterior (que está más cerca a la salida de la red). A estas conexiones se las denomina conexiones hacia adelante o feedforward. [1]




Figura 6: Red Neuronal Multicapa (feedforward)[6]

Sin embargo, en un gran número de estas redes también existe la posibilidad de conectar la salida de las neuronas de capas posteriores a la entrada de capas anteriores; a estas conexiones se las denomina conexiones hacia atrás o feedback.[1]




Figura 7: Red Neuronal Multicapa (feedback)[6]

Estas dos posibilidades permiten distinguir entre dos tipos de redes con múltiples capas: las redes con conexiones hacia adelante o redes feedforward, y las redes que disponen de conexiones tanto hacia adelante como hacia atrás o redes feedforward/feedback. [1]

9.4 Conexión entre neuronas

La conectividad entre los nodos de una red neuronal está relacionada con la forma en que las salidas de las neuronas están canalizadas para convertirse en entradas de otras neuronas. La señal de salida de un nodo puede ser una entrada de otro elemento de proceso, o incluso ser una entrada de sí mismo (conexión autorrecurrente).

Cuando ninguna salida de las neuronas es entrada de neuronas del mismo nivel o de niveles precedentes, la red se describe como de conexión hacia delante. Cuando las salidas pueden ser conectadas como entradas de neuronas de niveles previos o del mismo nivel, incluyéndose ellas mismas, la red es de conexión hacia atrás.

Las redes de propagación hacia atrás que tienen lazos cerrados son llamadas: sistemas recurrentes. [1]

9.5 Redes de propagación hacia atrás (backpropagation)

El nombre de backpropagation resulta de la forma en que el error es propagado hacia atrás a través de la red neuronal, en otras palabras, el error se propaga hacia atrás desde la capa de salida. Esto permite que los pesos sobre las conexiones de las neuronas ubicadas en las capas ocultas cambien durante el entrenamiento.

El cambio de los pesos en las conexiones de las neuronas además de influir sobre la entrada global, influye en la activación y por consiguiente en la salida de una neurona. Por lo tanto, es de gran utilidad considerar las variaciones de la función activación al modificarse el valor de los pesos. Esto se llama sensibilidad de la función activación, de acuerdo al cambio en los pesos. [1]

9.6 Estructura de la Red Hopfield.

La Red Hopfield es recurrente y completamente interconectada. Funciona como una memoria asociativa no lineal, que puede almacenar internamente patrones presentados de forma incompleta o con ruido. De esta forma puede ser usada como una herramienta de optimización; también se han utilizado en aplicaciones de segmentación y restauración de imágenes y optimización combinatoria.

Las Redes Hopfield se emplean para reconocer patrones. Después que el aprendizaje haya llegado a su fin, la red neuronal debe ser capaz de dar una salida correcta para cada patrón de entrada dado, aun cuando este sea ruidoso.

La clave del aprendizaje Hopfield es que, si un patrón que tiene que ser aprendido se conoce, los pesos sobre cada conexión de la red neuronal pueden ser calculados. En esta circunstancia, solamente el estado de las neuronas cambia durante el proceso de aprendizaje. [1]

10. Aplicaciones de las Redes Neuronales

Las redes neuronales pueden utilizarse en un gran número y variedad de aplicaciones, tanto comerciales como militares.

Se pueden desarrollar redes neuronales en un periodo de tiempo razonable, con la capacidad de realizar tareas concretas mejor que otras tecnologías. Cuando se implementan mediante hardware (redes neuronales en chips VLSI), presentan una alta tolerancia a fallos del sistema y proporcionan un alto grado de paralelismo en el procesamiento de datos. Esto posibilita la inserción de redes neuronales de bajo coste en sistemas existentes y recientemente desarrollados.

Desde el punto de vista de los casos de aplicación, la ventaja de las redes neuronales reside en el procesado paralelo, adaptativo y no lineal.

El dominio de aplicación de las redes neuronales se lo puede clasificar de la siguiente forma: asociación y clasificación, regeneración de patrones, regresión y generalización, y optimización. [1]

10.1 Asociación y clasificación

En esta aplicación, los patrones de entrada estáticos o señales temporales deben ser clasificadas o reconocidas. Idealmente, un clasificador debería ser entrenado para que cuando se le presente una versión distorsionada ligeramente del patrón, pueda ser reconocida correctamente sin problemas. De la misma forma, la red debería presentar cierta inmunidad contra el ruido, esto es, debería ser capaz de recuperar una señal "limpia" de ambientes o canales ruidosos. Esto es fundamental en las aplicaciones holográficas, asociativas o regenerativas. [1]

10.2 Regeneración de patrones

En muchos problemas de clasificación, una cuestión a solucionar es la recuperación de información, esto es, recuperar el patrón original dada solamente una información parcial. Hay dos clases de problemas: temporales y estáticos. El uso apropiado de la información contextual es la llave para tener éxito en el reconocimiento. [1]

10.3 Regeneración y generalización

El objetivo de la generalización es dar una respuesta correcta a la salida para un estímulo de entrada que no ha sido entrenado con anterioridad. El sistema debe inducir la característica saliente del estímulo a la entrada y detectar la regularidad. Tal habilidad para el descubrimiento de esa regularidad es crítica en muchas aplicaciones. Esto hace que el sistema funcione eficazmente en todo el espacio, incluso cuando ha sido entrenado por un conjunto limitado de ejemplos. [1]

10.4 Optimización

Las Redes Neuronales son herramientas interesantes para la optimización de aplicaciones, que normalmente implican la búsqueda del mínimo absoluto de una función de energía. Para algunas aplicaciones, la función de energía es fácilmente deducible; pero en otras, sin embargo, se obtiene de ciertos criterios de coste y limitaciones especiales. [1]

11. Conclusión

Las Redes Neuronales Artificiales, presenta grandes ventajas con respecto a otros modelos típicos de solución de problemas de Ingeniería, una de ellas es su inspiración en modelos biológicos del funcionamiento del cerebro, lo que facilita su estudio debido a las analogías que pueden introducirse para su análisis.

Permiten el aprendizaje por medio de patrones, pueden solucionar problemas no lineales y de alta complejidad, son un instrumento muy flexible para la solución de problemas, junto con otras técnicas de inteligencia artificial, ha generado soluciones muy confiables siendo una alternativa fácil de implementar y altamente segura.

La principal ventaja de las redes neuronales es su capacidad para aprender de la experiencia, de generalizar de casos anteriores a nuevos casos, de abstraer características esenciales a partir de entradas que representan información irrelevante; en términos generales las redes neuronales son una teoría relativamente nueva y como tal presentan aún algunas limitaciones, pero su facilidad de implementación y la calidad en la información que entregan como respuesta, son la motivación suficiente para que su estudio y desarrollo continúe.

Podemos mencionar algunas áreas de aplicación:

- Identificación de sistemas y el control: control vehicular para automóviles autónomos.
- Finanzas: para calcular la predicción del tipo de cambio y el rendimiento del stock en muchos años consecutivos.
- Telecomunicaciones: prevención de spam (correo basura) de correo electrónico.
- Reconocimiento de imágenes: Se han implementado para diagnosticar el cáncer usando sólo información de la forma de la célula.[7]

12. Referencias Bibliográficas

- [1] Universidad Tecnológica Nacional – Facultad Regional Rosario Departamento de Ingeniería Química Grupo de Investigación Aplicada a la Ingeniería Química (GIAIQ). “Redes Neuronales: Conceptos Básicos y Aplicaciones” Rosario – Marzo del 2001 [Online]. Available: https://www.frro.utn.edu.ar/repositorio/catedras/quimica/5_anio/orientadora1/monograias/matich-redesneuronales.pdf
- [2] Extracción y Recuperación de Información. “Ingeniería de Datos. Redes Bayesianas y Neuronales”, Abril 2016. [Online]. Available: <https://sites.google.com/site/extraccionyrecuperaciondeinfo/noticias/mineriadedatosredesbayesianasyneuronales>
- [3] C. Pérez López and D. Santin González, Minería de datos, Técnicas y herramientas. Madrid España 2008.
- [4] D.V. La Red Martínez, “Minería de Datos – Redes Neuronales”, en “Base de Datos 2 – Presentaciones de la asignatura”, UNNE, Corrientes, 2020. [Online] Available: http://exa.unne.edu.ar/depar/areas/informatica/dad/BDII/Presentaciones_Proyector/Mineria_de_Datos_Red_Neuronales.pdf
- [5] danner-informatico.blogspot.com. “Aprendizaje de una red de neurona”, Febrero 2016. [Online]. Available: <http://danner-informatico.blogspot.com/2016/02/aprendizaje-de-una-red-de-neurona.html>
- [6] grupo.us.es, “Conceptos Básicos Sobre Redes Neuronales”. [Online]. Available: <http://grupo.us.es/gtocom/pid/pid10/RedesNeuronales.htm>
- [7] Medicina y Complejidad. “Diplomado en Ciencia Médica y Ciencia de la Complejidad” Mayo 2019. [Online] Available: <http://medicinaycomplejidad.org/pdf/redes/Conclusiones.pdf>