

1) Algoritmo ID3

Para resolver estos casos hay que tener en cuenta el algoritmo denominado **ID3**.

ID3 es un algoritmo matemático que permite generar un árbol de decisión, se construye de arriba hacia abajo y emplea el concepto de ganancia de la información para seleccionar el atributo más útil en cada caso.

Donde tenemos que:

- Cada nodo que no sea hoja representa un atributo
- Las aristas o ramas están etiquetados con cada uno de los posibles valores que puede tomar el atributo
- Los nodos hojas contiene los valores de la clasificación

De la tabla de datos proporcionada, para saber si se puede jugar al fútbol, la entropía que tiene el sistema respecto a la clasificación de si se juega o no, es aplicando la siguiente fórmula:

$$\text{Entropía}(S) = E(S) = - \sum_{i=1}^C p_i * \log_2 (p_i)$$

La **entropía** permite calcular el grado de incertidumbre de una muestra, si la muestra es totalmente homogénea la entropía es igual a 0 y si la muestra es igualmente distribuida tiene entropía igual a 1.

Donde S es el conjunto de muestras (el sistema analizado), C es el número de diferentes clasificaciones que usamos (Si y No), y cada p_i es la proporción/probabilidad de ejemplos/casos que hay de la clasificación i en la muestra.

Recordemos que podemos calcular $\log_2 (p_i) = \log_{10}(p_i) / \log_{10}(2)$ y que debido a que no está definido el $\log_x(0)$, tomaremos siempre que $0 \log_2(0) = 0$.

En el caso particular de una clasificación binaria (que podríamos denotar como casos positivos - Si / negativos - No), la fórmula anterior queda como:

$$E(S) = (- P \log_2(P)) + (- N \log_2(N))$$

donde P y N son, respectivamente, la proporción de casos positivos y negativos, positivo es si es posible jugar y negativo cuando no es posible jugar al fútbol.

Considerando el lote de datos en análisis:

Jugar fútbol	
Si	No
9	5
Probabilidad=9/14	Probabilidad=5/14

Se evalúan 14 días en total de la muestra considerada.

$$\text{Entropía}(\text{Jugarfútbol}) = \text{Entropía}(9,5) = (-9/14 \log_2 (9/14)) + (-5/14 \log_2 (5/14)) = \mathbf{0,94}$$

Si obtenemos $\log_2$ de cada probabilidad:

$$\log_2 (9/14) = \log_2 (0,64) = \log_{10}(0,64) / \log_{10}(2) = -0,64$$

$$\log_2 (5/14) = \log_2 (0,36) = \log_{10}(0,36) / \log_{10}(2) = -1,47$$

$$E(\text{Jugarfútbol}) = (-9/14 * (-0,64)) + (-5/14 * (-1,47)) = (-0,64 * (-0,64)) + (-0,36 * (-1,47)) = \mathbf{0,9388 = 0,94}$$

Ganancia de la información:

- Se basa en el decremento de la entropía cuando el conjunto de datos se divide en los valores de un atributo
- ¿Qué atributo crea las ramas más homogéneas?
 - ✓ Se calcula la entropía total (Entropía(Jugarfútbol))
 - ✓ Se divide el conjunto de datos en función de los diferentes atributos
 - ✓ Se calcula la entropía de cada rama y se suman proporcionalmente las ramas para calcular la entropía del total
 - ✓ Se resta este resultado de la entropía total (E(Jugarfútbol))

- ✓ El resultado es la ganancia de información, descenso de entropía
- ✓ El atributo con mayor ganancia se selecciona como nodo de decisión
- ✓ Una rama con entropía 0 se convierte en hoja (nodo-respuesta, todos sus casos ya están clasificados), ya que representa una muestra completamente homogénea, en la que todos los casos tienen la misma clasificación
- ✓ Si no es así, la rama debe seguir subdividiéndose, para clasificar mejor sus nodos
- ✓ El algoritmo ID3 se ejecuta recursivamente en nodos que no son hojas, hasta que se llegue a nodos hoja

¿Qué atributo crea las ramas más homogéneas y, por tanto, proporciona una ganancia de información mayor?

Para ello, hay que ir determinando la entropía asociada a cada atributo X, sería:

$$\text{Entropía}(S, X) = E(S, X) = \sum_{c \in X} P(c) E(c)$$

c son los posibles valores que puede tomar el atributo X

E(c) es la entropía respecto a los casos positivos "Si" y casos negativos "No" que puede tomar **c**, **E(P_c, N_c)**.

Y la ganancia de información que aportaría dividir respecto a los valores de ese atributo, resulta de:

$$\text{Ganancia}(S, X) = G(S, X) = E(S) - E(S, X)$$

Calculemos la ganancia que obtendríamos si hiciéramos una división usando el primer atributo **Tiempo**:

		Jugar fútbol		
		Si	No	
Tiempo	soleado	2	3	5
	nublado	4	0	4
	lluvia	3	2	5
				14

Entropía(Jugarfútbol, Tiempo) =

$$\begin{aligned} E(\text{Jugarfútbol, Tiempo}) &= P(\text{soleado}) * E(2,3) + P(\text{nublado}) * E(4,0) + P(\text{lluvia}) * E(3,2) = \\ &= (5/14) * 0,971 + (4/14) * 0 + (5/14) * 0,971 = 0,3751 * 0,971 + \\ &= 0,3751 * 0,971 = 0,693 \end{aligned}$$

Para este atributo, obtendremos las entropías de los casos positivos y negativos que pueden tomar cada uno de sus valores:

$$\begin{aligned} E(\text{soleado}) &= E(2,3) = E(2/5, 3/5) = E(0,4, 0,60) = (-0,4 \log_2(0,4)) + (-0,60 \log_2(0,60)) = \\ &= (-0,4 * -1,3219) + (-0,6 * -0,7369) = 0,52876 + 0,44214 = 0,9709 \end{aligned}$$

por lo que

$$E(\text{soleado}) = E(2,3) = 0,971$$

Para calcular los logaritmos tenemos:

$$\log_2(2/5) = \log_2(0,4) = \log_{10}(0,40) / \log_{10}(2) = -0,39794 / 0,301029 = -1,3219$$

$$\log_2(3/5) = \log_2(0,6) = \log_{10}(0,60) / \log_{10}(2) = -0,22184 / 0,301029 = -0,7369$$

$$E(\text{nublado}) = E(4,0) = E(4/4, 0/4) = E(1,0) = (-1 \log_2(1)) + (-0 \log_2(0)) = 0 + 0 = 0$$

$$\log_2(1) = \log_{10}(1) / \log_{10}(2) = 0 / 0,301029 = 0$$

$$\log_2(0) = \log_{10}(0) = 0 \text{ al no existir logaritmo en base}_{10} \text{ para el valor } 0, \text{ consideramos igual a } 0$$

$$\begin{aligned} E(\text{lluvia}) &= E(3,2) = E(3/5, 2/5) = E(0,6, 0,40) = (-0,6 \log_2(0,6)) + (-0,40 \log_2(0,40)) = \\ &= (-0,6 * -0,7369) + (-0,4 * -1,3219) = 0,44214 + 0,52876 = 0,9709 \end{aligned}$$

por lo que

$$E(\text{lluvia}) = E(3,2) = 0,971$$

Ahora debemos de obtener la ganancia de información para el atributo tiempo, para ello consideramos la diferencia entre la entropía total y la entropía tiempo:

$$G(\text{Jugarfútbol, Tiempo}) = E(\text{Jugarfútbol}) - E(\text{Jugarfútbol, Tiempo}) = 0,94 - 0,693 = 0,247$$

$$\text{Ganancia}(\text{Jugarfútbol, Tiempo}) = 0,25$$

Ahora debemos de replicar este procedimiento para los demás atributos de los casos:

Ganancia del atributo **Temperatura**:

		Jugar fútbol		
		Si	No	
Temperatura	alta	2	2	4
	templada	4	2	6
	frío	3	1	4
				14

$$E(\text{Jugar fútbol, Temperatura}) = P(\text{alta}) * E(2,2) + P(\text{templada}) * E(4,2) + P(\text{frío}) * E(3,1) = \\ (4/14) * E(2/4,2/4) + (6/14) * E(4/6,2/6) + (4/14) * E(3/4,1/4) = \\ 0,28571 * 1 + 0,42857 * 0,918301 + 0,28571 * 0,81127 = 0,91104$$

$$G(\text{Jugar fútbol, Temperatura}) = 0,94 - 0,91104 = 0,0289 = 0,03$$

Ganancia del atributo **Humedad**:

		Jugar fútbol		
		Si	No	
Humedad	alta	3	4	7
	normal	6	1	7
				14

$$E(\text{Jugar fútbol, Humedad}) = P(\text{alta}) * E(3,4) + P(\text{normal}) * E(6,1) = \\ (7/14) * E(3/7,4/7) + (7/14) * E(6/7,1/7) = \\ 0,5 * 0,9851 + 0,5 * 0,5915 = 0,7883$$

$$G(\text{Jugar fútbol, Humedad}) = 0,94 - 0,7883 = 0,15$$

Ganancia del atributo **Viento**:

		Jugar fútbol		
		Si	No	
Viento	débil	6	2	8
	fuerte	3	3	6
				14


$$E(\text{Jugar fútbol, Viento}) = P(\text{débil}) * E(6,2) + P(\text{fuerte}) * E(3,3) = \\ (8/14) * E(6/8,2/8) + (6/14) * E(3/6,3/6) = \\ 0,571 * 0,8112 + 0,428 * 1 = 0,8911$$

$$G(\text{Jugar fútbol, Viento}) = 0,94 - 0,8911 = 0,0489 = 0,05$$

Las ganancias de los atributos calculados son:


Atributos	Ganancia de información
Tiempo	0,25
Temperatura	0,03
Humedad	0,15
Viento	0,05

Vamos a elegir el atributo que proporciona mayor ganancia, en este caso corresponde a **Tiempo**, por lo que podemos construir el primer paso del árbol de decisión, identificando el primer nodo de decisión:



Un nodo que tenga entropía nula se convierte en un nodo respuesta, ya que representa una muestra homogénea en el que la clasificación final es la misma para todos los ejemplos/casos que contiene.

También podemos representar de la siguiente manera:



A continuación, nos situamos en cada uno de los subconjuntos de casos que define cada valor del atributo seleccionado y repetimos el proceso, construyendo poco a poco el árbol completo de decisión.

Ahora seleccionados de la tabla las filas que corresponde al valor "**soleado**" para el atributo Tiempo, repetimos los cálculos, pero con esta muestra menor.

Tiempo	Temperatura	Humedad	Viento	Jugar fútbol
soleado	alta	Alta	débil	no
soleado	alta	Alta	fuerte	no
soleado	templada	Alta	débil	no
soleado	frio	Normal	débil	si
soleado	templada	Normal	fuerte	si

Obtenemos la entropía de este lote de datos:

$$E(\text{soleado}) = E(2,3) = -(2/5) * \log(2/5;2) - (3/5) * \log(3/5;2) = \mathbf{0,97}$$

$$E(\text{soleado}) = -(0,4) * (-1,3219) - (0,6) * (-0,7369) = 0,52876 + 0,44214 = \mathbf{0,97}$$

Ganancia del atributo **Temperatura**:

		Soleado		
		Si	No	
Temperatura	alta	0	2	2
	templada	1	1	2
	Frío	1	0	1
				5

$$E(\text{soleado, Temperatura}) = P(\text{alta}) * E(0,2) + P(\text{templada}) * E(1,1) + P(\text{frío}) * E(1,0) = \\ (2/5) * E(0/2,2/2) + (2/5) * E(1/2,1/2) + (1/5) * E(1/1,0/1) = \\ 0,4 * 0 + 0,4 * 1 + 0,2 * 0 = \mathbf{0,4}$$

$$G(\text{soleado, Temperatura}) = \mathbf{0,97 - 0,4 = 0,57}$$

Ganancia del atributo **Humedad**:

		Soleado		
		Si	No	
Humedad	alta	0	3	3
	normal	2	0	2
				5

$$E(\text{soleado, Humedad}) = P(\text{alta}) * E(0,3) + P(\text{normal}) * E(2,0) = \\ (3/5) * E(0/3,3/3) + (2/5) * E(2/2,0/2) = 0,6*0 + 0,4*0 = \mathbf{0}$$

$$G(\text{soleado, Humedad}) = \mathbf{0,97 - 0 = 0,97}$$

Ganancia del atributo **Viento**:

		Soleado		
		Si	No	
Viento	débil	1	2	3
	fuerte	1	1	2
				5



$$E(\text{soleado, Viento}) = P(\text{débil}) * E(1,2) + P(\text{fuerte}) * E(1,1) = \\ (3/5) * E(1/3,2/3) + (2/5) * E(1/2,1/2) = \\ 0,6 * 0,9183 + 0,4 * 1 = \mathbf{0,95098}$$

$$G(\text{soleado, Viento}) = \mathbf{0,97 - 0,95098 = 0,019 = 0,02}$$

Las ganancias de los atributos calculados son:

Atributos	Ganancia de información
Temperatura	0,57
Humedad	0,97
Viento	0,02

Representamos en nuestro árbol de decisión:



Por último, nos queda evaluar de la tabla las filas que corresponde al valor "**lluvia**" para el atributo Tiempo.

Tiempo	Temperatura	Humedad	Viento	Jugar fútbol
lluvia	templada	Alta	débil	si
lluvia	frio	Normal	débil	si
lluvia	frio	Normal	fuerte	no
lluvia	templada	Normal	débil	si
lluvia	templada	Alta	fuerte	no

Obtenemos la entropía de este lote de datos:

$$E(\text{lluvia}) = E(3,2) = -(3/5) * \log(3/5;2) + -(2/5) * \log(2/5;2) = \mathbf{0,97}$$

Ganancia del atributo **Temperatura**:

		lluvia		
		Si	No	
Humedad	templada	2	1	3
	frío	1	1	2
				5

$$E(\text{lluvia, Temperatura}) = P(\text{templada}) * E(2,1) + P(\text{frío}) * E(1,1) =$$

$$(3/5) * E(2/3, 1/3) + (2/5) * E(1/2, 1/2) =$$

$$0,6 * 0,9183 + 0,4 * 1 = 0,9598$$

$$G(\text{lluvia, Temperatura}) = 0,97 - 0,9598 = 0,019 = 0,02$$

Ganancia del atributo **Humedad**:

		lluvia		
		Si	No	
Humedad	alta	1	1	2
	normal	2	1	3
				5

$$E(\text{lluvia, Humedad}) = P(\text{alta}) * E(1,1) + P(\text{normal}) * E(2,1) =$$

$$(2/5) * E(1/2, 1/2) + (3/5) * E(2/3, 1/3) =$$

$$0,4 * 1 + 0,6 * 0,9183 = 0,9598$$

$$G(\text{lluvia, Humedad}) = 0,97 - 0,9598 = 0,019 = 0,02$$

Ganancia del atributo **Viento**:

		lluvia		
		Si	No	
Viento	débil	3	0	3
	fuerte	0	2	2
				5

$$E(\text{lluvia, Viento}) = P(\text{débil}) * E(3,0) + P(\text{fuerte}) * E(0,2) =$$


$$(3/5) * E(3/3, 0/3) + (2/5) * E(0/2, 2/2) = 0,6 * 0 + 0,4 * 0 = 0$$


$$G(\text{lluvia, Viento}) = 0,97 - 0 = 0,97$$

Las ganancias de los atributos calculados son:

Atributos	Ganancia de información
Temperatura	0,02
Humedad	0,02
Viento	0,97

El árbol de decisión final será:





La verificación de que, si es posible o no jugar al fútbol, la realizamos desde arriba y hacia abajo del árbol resultante.

- 2) Aplicar el algoritmo “**apriori**” para encontrar las reglas que predicen la ocurrencia de un ítem. Considerado al soporte mínimo = 2 (support – supp - minsup) y para la confianza = 0.75 (confidence – conf - minconf).

En la tabla se indican una colección de ítems que un cliente de un supermercado compra en una misma transacción, el problema viene dado por identificar el conjunto de ítems que son adquiridos en conjunto, siendo esta una de sus aplicaciones, la del análisis de los carros de compras.

Transacción	Ítems
1	Aceite, leche, azúcar
2	Aceite, yerba, cerveza, azúcar
3	Leche, yerba, cerveza, sal
4	Aceite, leche, yerba, cerveza, sal
5	Aceite, leche, yerba, sal

Transacción	Aceite	Leche	Yerba	Cerveza	Azúcar	Sal
1	1	1	0	0	1	0
2	1	0	1	1	1	0
3	0	1	1	1	0	1
4	1	1	1	1	0	1
5	1	1	1	0	0	1

Se deben de encontrar las reglas de asociación con valores de soporte y confianza, que cumplan con los umbrales mínimos establecidos por el usuario en cuanto al soporte mínimo y confianza mínima (minsup y minconf), en este caso minsup = 2 y minconf = 0.75.

Para lo cual tenemos:

$I = \{i_1, i_2, i_3, \dots, i_n\}$ es el conjunto de ítems

D es conjunto de transacciones T_j

Cada transacción T_j es un subconjunto de ítems de entre los posibles ítems definidos en I .

$I = \{\text{Aceite, Leche, Yerba, Cerveza, Azúcar, Sal}\}$

$D = \{1, 2, 3, 4, 5\} = \{\{\text{Aceite, Leche, Azúcar}\}, \{\text{Aceite, Azúcar, Yerba, Cerveza}\}, \{\text{Leche, Yerba, Cerveza, Sal}\}, \{\text{Aceite, Leche, Yerba, Cerveza, Sal}\}, \{\text{Aceite, Leche, Yerba, Sal}\}\}$

A toda colección de cero o más ítems se denomina *itemset*. Si un *itemset* contiene k ítems, se le llama *k-itemset*. En el ejemplo de la cesta de la compra anterior la transacción $\{\text{Aceite, Azúcar, Yerba, Cerveza}\}$ es un ejemplo de un 4-itemset. Si tenemos un conjunto de datos con cero elementos también es válido y sería el *itemset* vacío.

El tamaño de una transacción lo definimos como el número de *ítems* presentes en la transacción. Una transacción t_j decimos que contiene un *itemset* X si X es un subconjunto de t_j . Por ejemplo, la segunda transacción de la Tabla contiene el *itemset* $\{\text{Aceite, Yerba}\}$ pero no contiene el *itemset* $\{\text{Aceite, Sal}\}$.

Una propiedad que se asocia a un *itemset* es su frecuencia de ocurrencia que se define como el número de transacciones que contienen dicho *itemset*. Podemos ver que el *itemset* {Aceite, Yerba} aparece en 3 transacciones por lo que su frecuencia de ocurrencia es 3.

Una regla de asociación es una expresión que tiene la forma $X \rightarrow Y$ donde X e Y son itemsets disjuntos. Para medir la fuerza de una regla de asociación se utilizan los conceptos de soporte y confianza.

El **soporte** de una regla es la proporción de transacciones que contienen el itemset formado por los ítems que aparecen en el antecedente y consecuente de la regla.

La **confianza** de una regla es la proporción de transacciones que conteniendo los ítems del antecedente de la regla también contienen los ítems del consecuente de la regla, es decir, la proporción de transacciones para las que se cumple la regla.

Las definiciones formales que son las siguientes:

$$\text{soporte } \{X \rightarrow Y\} = \frac{X \cup Y}{N} \qquad \text{confianza } \{X \rightarrow Y\} = \frac{X \cup Y}{X}$$

Veamos un ejemplo de estos conceptos basado en los elementos del carrito de compra de nuestro caso.

Consideremos la regla {Aceite, Leche} $\rightarrow$ {Yerba}, como sabemos que la frecuencia de ocurrencia de {Aceite, Leche, Yerba} es 2 y el número total de transacciones es 5 el soporte de la regla es 2/5, es decir, igual a 0,4 que representa un 40%.

La confianza de la regla se obtiene dividiendo la frecuencia de ocurrencia de {Aceite, Leche, Yerba} entre la frecuencia de ocurrencia de {Aceite, Leche}. Como hay 3 transacciones que contienen {Aceite, Leche} la confianza para esta regla es 2/3. Es decir, igual a 0,66, la regla se cumple en el 66% de los casos.

El proceso de generación de reglas de asociación consiste en encontrar, para un conjunto de transacciones, todas las reglas que tengan un soporte y confianza iguales o superiores a unos valores mínimos a los que se denomina minsup y minconf, fijados por el usuario.

Este proceso puede descomponerse en 2 fases para facilitar su implementación.

A.-Generación de los itemsets frecuentes

Cuyo objetivo es descubrir todos los itemsets que satisfagan el umbral minsup (soporte mínimo). Estos itemsets descubiertos serán los denominados itemsets frecuentes.

B.-Generación de Reglas

Cuyo objetivo es extraer, a partir de los itemsets frecuentes encontrados en el paso previo, todas las reglas que cumplan con el grado de confianza minconf (confianza mínima).

Se inicia el algoritmo identificando todos los *ítems* individuales (*itemsets* de un único *ítem*) y calculando su soporte.

Para la tabla presentada, el soporte de cada uno de los ítems es de:

Ítem	Soporte	Soporte mínimo
{Aceite}	4	4/5=0,80=80%
{Leche}	4	4/5=0,80=80%
{Yerba}	4	4/5=0,80=80%
{Cerveza}	3	3/5=0,60=60%
{Azúcar}	2	2/5=0,40=40%
{Sal}	3	3/5=0,60=60%

Indica la cantidad de veces que aparece cada ítem en las transacciones evaluadas.

Todos los *itemsets* de tamaño $k = 1$ tienen un soporte igual o superior al mínimo establecido, por lo que todos superan la fase de filtrado (poda).

Otra forma de representar es:

$S_1 = \{\{Aceite\}:4, \{Leche\}:4, \{Yerba\}:4, \{Cerveza\}:3, \{Azúcar\}:2, \{Sal\}:3\}$

A continuación, veremos la generación de itemsets frecuentes usando el algoritmo a priori.

Fase A – Conjuntos Frecuentes

Combinaciones de 2 ítems, itemset ($k=2$): 2-itemset

$S_2 = \{$
 {Aceite, Leche}, {Aceite, Yerba}, {Aceite, Cerveza}, {Aceite, Azúcar}, {Aceite, Sal},
 {Leche, Yerba}, {Leche, Cerveza}, {Leche, Azúcar}, {Leche, Sal},
 {Yerba, Cerveza}, {Yerba, Azúcar}, {Yerba, Sal}
 {Cerveza, Azúcar}, {Cerveza, Sal}
}

Vemos el soporte de cada regla:

$S_2 = \{$
 {Aceite, Leche}:3, {Aceite, Yerba}:3, {Aceite, Cerveza}:2, {Aceite, Azúcar}:2, {Aceite, Sal}:2,
 {Leche, Yerba}:3, {Leche, Cerveza}:2, {Leche, Azúcar}:1, {Leche, Sal}:3,
 {Yerba, Cerveza}:3, {Yerba, Azúcar}:1, {Yerba, Sal}:3,
 {Cerveza, Azúcar}:1, {Cerveza, Sal}:2
}

Quitamos aquellas reglas que no llegan a cumplir con el minsup solicitado, igual a 2, quedando aquellas que son iguales o mayores a ese valor:

$S_2 = \{$
 {Aceite, Leche}:3, {Aceite, Yerba}:3, {Aceite, Cerveza}:2, {Aceite, Azúcar}:2, {Aceite, Sal}:2,
 {Leche, Yerba}:3, {Leche, Cerveza}:2, {Leche, Sal}:3,
 {Yerba, Cerveza}:3, {Yerba, Sal}:3,
 {Cerveza, Sal}:2
}

Combinaciones de 3 ítems (recorriendo cada transacción) y contabilizando en una regla las ocurrencias que se repiten, itemset ($k=3$): 3-itemset

$S_3 = \{$
 {Aceite, Leche, Azúcar}:1,
 {Aceite, Yerba, Cerveza}:2, {Aceite, Yerba, Azúcar}:1, {Aceite, Cerveza, Azúcar}:1,
 {Leche, Yerba, Cerveza}:2, {Leche, Yerba, Sal}:3, {Leche, Cerveza, Sal}:2,
 {Aceite, Leche, Yerba}:2, {Aceite, Leche, Cerveza}:1, {Aceite, Leche, Sal}:2,
 {Aceite, Yerba, Sal}:2,
 {Aceite, Cerveza, Sal}:1, {Yerba, Cerveza, Sal}:2,
}

Y aquellas reglas que cumplen con el minsup de 2, son:

$S_3 = \{$
 {Aceite, Yerba, Cerveza}:2,
 {Leche, Yerba, Cerveza}:2, {Leche, Yerba, Sal}:3, {Leche, Cerveza, Sal}:2,
 {Aceite, Leche, Yerba}:2, {Aceite, Leche, Sal}:2,
 {Aceite, Yerba, Sal}:2,
 {Yerba, Cerveza, Sal}:2,
}

Combinaciones de 4 ítems (recorriendo cada transacción) y contabilizando en una regla las ocurrencias que se repiten, itemset ($k=4$):

$S_4 = \{$
 {Aceite, Azúcar, Yerba, Cerveza}:1,
 {Leche, Yerba, Cerveza, Sal}:2,
 {Aceite, Leche, Yerba, Cerveza}:1, {Aceite, Leche, Yerba, Sal}:2,
 {Aceite, Leche, Cerveza, Sal}:1, {Aceite, Yerba, Cerveza, Sal}:1,
}

Quedando las de soporte:

$S_4 = \{$
 {Leche, Yerba, Cerveza, Sal}:2,
 {Aceite, Leche, Yerba, Sal}:2,
}

Combinaciones de 5 ítems solo se da una regla, itemset ($k=5$), que no configura con el soporte mínimo:

$S_5 = \{\{Aceite, Leche, Yerba, Cerveza, Sal\}:1\}$

De las reglas que cumplen con el soporte mínimo establecido, tenemos a los conjuntos conformados por 2, 3 y 4 ítems:

$$S_{\text{final}} = S_2 \cup S_3 \cup S_4 =$$

{
 {Aceite, Leche}:3, {Aceite, Yerba}:3, {Aceite, Cerveza}:2, {Aceite, Azúcar}:2, {Aceite, Sal}:2,
 {Leche, Yerba}:3, {Leche, Cerveza}:2, {Leche, Sal}:3,
 {Yerba, Cerveza}:3, {Yerba, Sal}:3,
 {Cerveza, Sal}:2
 {Aceite, Yerba, Cerveza}:2,
 {Leche, Yerba, Cerveza}:2, {Leche, Yerba, Sal}:3, {Leche, Cerveza, Sal}:2,
 {Aceite, Leche, Yerba}:2, {Aceite, Leche, Sal}:2,
 {Aceite, Yerba, Sal}:2,
 {Yerba, Cerveza, Sal}:2,
 {Leche, Yerba, Cerveza, Sal}:2,
 {Aceite, Leche, Yerba, Sal}:2,
 }

Fase B – Generación de Reglas, evaluación de la confianza

A partir de S_{final} de los soportes mínimos, ahora calcularemos la confianza para luego obtener aquellas reglas de asociación candidatas que cumplan al menos con el soporte y confianza en sus valores mínimos.

Recordemos que: $\text{soporte } \{X \rightarrow Y\} = \frac{X \cup Y}{N}$ $\text{confianza } \{X \rightarrow Y\} = \frac{X \cup Y}{X}$

Ítemsets frecuentes	Soporte mínimo	Confianza
{Aceite, Leche}	3	$\text{conf}(\{Aceite, Leche\}) = \text{supp}(\{Aceite, Leche\}) / \text{supp}(\{Aceite\}) = (3/5) / (4/5) = 3/4 = 0.75$
{Aceite, Yerba}	3	$\text{conf}(\{Aceite, Yerba\}) = \text{supp}(\{Aceite, Yerba\}) / \text{supp}(\{Aceite\}) = (3/5) / (4/5) = 3/4 = 0.75$
{Aceite, Cerveza}	2	$\text{conf}(\{Aceite, Cerveza\}) = \text{supp}(\{Aceite, Cerveza\}) / \text{supp}(\{Aceite\}) = (2/5) / (4/5) = 2/4 = 0.50$
{Aceite, Azúcar}	2	$\text{conf}(\{Aceite, Azúcar\}) = \text{supp}(\{Aceite, Azúcar\}) / \text{supp}(\{Aceite\}) = (2/5) / (4/5) = 2/4 = 0.50$
{Aceite, Sal}	2	$\text{conf}(\{Aceite, Sal\}) = \text{supp}(\{Aceite, Sal\}) / \text{supp}(\{Aceite\}) = (2/5) / (4/5) = 2/4 = 0.50$
{Leche, Yerba}	3	$\text{conf}(\{Leche, Yerba\}) = \text{supp}(\{Leche, Yerba\}) / \text{supp}(\{Leche\}) = (3/5) / (4/5) = 3/4 = 0.75$
{Leche, Cerveza}	2	$\text{conf}(\{Leche, Cerveza\}) = \text{supp}(\{Leche, Cerveza\}) / \text{supp}(\{Leche\}) = (2/5) / (4/5) = 2/4 = 0.50$
{Leche, Sal}	3	$\text{conf}(\{Leche, Sal\}) = \text{supp}(\{Leche, Sal\}) / \text{supp}(\{Leche\}) = (3/5) / (4/5) = 3/4 = 0.75$
{Yerba, Cerveza}	3	$\text{conf}(\{Yerba, Cerveza\}) = \text{supp}(\{Yerba, Cerveza\}) / \text{supp}(\{Yerba\}) = (3/5) / (4/5) = 2/3 = 0.75$
{Yerba, Sal}	3	$\text{conf}(\{Yerba, Sal\}) = \text{supp}(\{Yerba, Sal\}) / \text{supp}(\{Yerba\}) = (2/5) / (4/5) = 2/4 = 0.50$
{Cerveza, Sal}	2	$\text{conf}(\{Cerveza, Sal\}) = \text{supp}(\{Cerveza, Sal\}) / \text{supp}(\{Cerveza\}) = (2/5) / (3/5) = 2/3 = 0.66$
{Aceite, Yerba, Cerveza}	2	$\text{conf}(\{Aceite, Yerba, Cerveza\}) = \text{supp}(\{Aceite, Yerba, Cerveza\}) / \text{supp}(\{Aceite, Yerba\}) = (2/5) / (3/5) = 0.66$
{Leche, Yerba, Cerveza}	2	$\text{conf}(\{Leche, Yerba, Cerveza\}) = \text{supp}(\{Leche, Yerba, Cerveza\}) / \text{supp}(\{Leche, Yerba\}) = (2/5) / (3/5) = 2/3 = 0.66$
{Leche, Yerba, Sal}	3	$\text{conf}(\{Leche, Yerba, Sal\}) = \text{supp}(\{Leche, Yerba, Sal\}) / \text{supp}(\{Leche, Yerba\}) = (3/5) / (3/5) = 1$
{Leche, Cerveza, Sal}	2	$\text{conf}(\{Leche, Cerveza, Sal\}) = \text{supp}(\{Leche, Cerveza, Sal\}) / \text{supp}(\{Leche, Cerveza\}) = (2/5) / (2/5) = 1$
{Aceite, Leche, Yerba}	2	$\text{conf}(\{Aceite, Leche, Yerba\}) = \text{supp}(\{Aceite, Leche, Yerba\}) / \text{supp}(\{Aceite, Leche\}) = (2/5) / (3/5) = 2/3 = 0.66$
{Aceite, Leche, Sal}	2	$\text{conf}(\{Aceite, Leche, Sal\}) = \text{supp}(\{Aceite, Leche, Sal\}) / \text{supp}(\{Aceite, Leche\}) = (2/5) / (3/5) = 0.66$
{Aceite, Yerba, Sal}	2	$\text{conf}(\{Aceite, Yerba, Sal\}) = \text{supp}(\{Aceite, Yerba, Sal\}) / \text{supp}(\{Aceite, Yerba\}) = (2/5) / (2/5) = 1$
{Yerba, Cerveza, Sal}	2	$\text{conf}(\{Yerba, Cerveza, Sal\}) = \text{supp}(\{Yerba, Cerveza, Sal\}) / \text{supp}(\{Yerba, Cerveza\}) = (2/5) / (3/5) = 2/3 = 0.66$
{Leche, Yerba, Cerveza, Sal}	2	$\text{conf}(\{Leche, Yerba, Cerveza, Sal\}) = \text{supp}(\{Leche, Yerba, Cerveza, Sal\}) / \text{supp}(\{Leche, Yerba, Cerveza\}) = (2/5) / (2/5) = 1$
{Aceite, Leche, Yerba, Sal}	2	$\text{conf}(\{Aceite, Leche, Yerba, Sal\}) = \text{supp}(\{Aceite, Leche, Yerba, Sal\}) / \text{supp}(\{Aceite, Leche, Yerba\}) = (2/5) / (2/5) = 1$

Finalmente, las reglas de asociación que cumplen con los pisos mínimos de soporte = 2 y confianza = 0.75 son:

Reglas	Soporte	Confianza
{Aceite, Leche}	3	0.75
{Aceite, Yerba}	3	0.75
{Leche, Yerba}	3	0.75
{Leche, Sal}	3	0.75
{Yerba, Cerveza}	3	0.75
{Leche, Yerba, Sal}	3	1
{Leche, Cerveza, Sal}	2	1
{Aceite, Yerba, Sal}	2	1
{Leche, Yerba, Cerveza, Sal}	2	1
{Aceite, Leche, Yerba, Sal}	2	1

3) Clasificar cada persona como alta o baja, según el algoritmo **On-Line k-MEANS.**

Los datos considerados son:

Número (Persona)	Altura
1	190
2	160
3	158
4	177
5	189
6	171
7	160
8	154
9	200
10	172

Resolución:

- a) Paso 1: obtener la altura promedio de las personas del lote de datos proporcionado:
 Σ altura de las personas / cantidad de personas:
 $(190 + 160 + 158 + 177 + 189 + 171 + 160 + 154 + 200 + 172) / 10 = \mathbf{1731/10 = 173,1}$
- b) Paso 2: clasificar a las personas según tengan una altura superior a la altura promedio como personas altas, y aquellas que estén por debajo de está, serán consideradas personas bajas:

Número (Persona)	Altura	Clasificación
1	190	Alta
2	160	Baja
3	158	Baja
4	177	Alta
5	189	Alta
6	171	Baja
7	160	Baja
8	154	Baja
9	200	Alta
10	172	Baja

4) Sea la siguiente tabla de **Navigation Trails:**

ID	Trail
1	$A_1 \longrightarrow A_2 \longrightarrow A_3 \longrightarrow A_4$
2	$A_1 \longrightarrow A_5 \longrightarrow A_3 \longrightarrow A_4 \longrightarrow A_1$
3	$A_5 \longrightarrow A_2 \longrightarrow A_4 \longrightarrow A_6$
4	$A_5 \longrightarrow A_2 \longrightarrow A_3$
5	$A_5 \longrightarrow A_2 \longrightarrow A_3 \longrightarrow A_6$
6	$A_4 \longrightarrow A_1 \longrightarrow A_5 \longrightarrow A_3$

Buscando Patrones de Navegación mediante HPGs (Borges and Levene 2000):

Las sesiones o log files de navegación toman la forma de secuencias de enlaces recorridos por un usuario, conocidos como *navigation trails* o sesiones.

Consideraremos al término enlace como sinónimo de página, documento, URL o visita.

Los '**navigation trails**' se utilizan para construir una Hypertext Probabilistic Grammar (HPG), podríamos traducirlo como Gramática Probabilística de Hipertexto.

Una HPG es una tupla $\langle V, \Sigma, S, P \rangle$. No es más que un tipo especial de gramáticas probabilísticas regulares, con la característica especial que tienen el mismo número de terminales S que no terminales V (con lo que se hace una correspondencia 1 a 1 entre ellos).

Se construye el grafo de transiciones de la gramática de la siguiente manera:

- Se añade un único nodo inicial S y un nodo final F , que no corresponden con ningún URL.
- Se añaden tantos nodos como URLs distintos haya en los distintos trails.

¿Qué valores probabilísticos ponemos en las flechas? (para saber las reglas de producción probabilística P).

Existen dos parámetros para construir el HPG:

- α : importancia de inicio.
- Si $\alpha = 0$ sólo habrá flechas de S a los nodos que han sido alguna vez inicio de sesión, y el valor de la flecha dependerá de cuántas veces lo han sido.
- Si $\alpha = 1$ el peso de las flechas dependerá de la probabilidad de visitas a cada nodo, independientemente de que fueran iniciales.
- Si $\alpha > 0$ habrá flechas con peso > 0 de S a todos los nodos.
- N (donde $N \geq 1$): valor de N-grama. Determina la memoria cuando se navega la red, es decir el número de URLs anteriores que pueden influir en la elección del próximo URL. Si $N=1$ el resultado será una cadena de Markov.

De aquí extraemos los no terminales y los terminales correspondientes:

$V = \{S, A_1, A_2, A_3, A_4, A_5, A_6, F\}$

$S = \{a_1, a_2, a_3, a_4, a_5, a_6\}$

Tenemos 6 trails y 24 visitas, donde A_1 , por ejemplo, fue visitada 4 veces, 2 de las cuales como página de inicio.

Por tanto, tomando $\alpha = 0,5$ y $N=1$, podemos calcular la probabilidad de la producción $p(S \rightarrow a_1 A_1)$ que corresponde con la flecha de S a A_1 en el grafo de transiciones de la siguiente manera:

$$p(S \rightarrow a_1 A_1) = (0,5 * 4)/24 + (0,5 * 2)/6 = 0,25$$

En primer lugar, tenemos en cuenta las ocurrencias en total del Nodo A_1 respecto a los 24 enlaces posibles, más las veces que el Nodo A_1 se encuentra como página de inicio respecto a los 6 posibles caminos dados.

Las flechas interiores se calculan de manera similar.

Por ejemplo, si A_4 se ha visitado 4 veces, 1 justo antes del final, otra antes de A_6 y dos antes de A_1 tenemos:

$$p(A_4 \rightarrow a_1 A_1) = 2/4$$

$$p(A_4 \rightarrow a_6 A_6) = 1/4$$

$$p(A_4 \rightarrow F) = 1/4$$

En las siguientes tablas podemos expresar el conjunto de producciones probabilísticas p derivadas de la tabla dada (para $\alpha=0,5$ y $N=1$), representamos por separado cada una y luego al final unificamos en una sola tabla:

Inicio producción (visitas de cada Nodo) + (veces Nodo al inicio)		
$S \rightarrow a_1 A_1$	$p(S \rightarrow a_1 A_1) = (0,5 * 4)/24 + (0,5 * 2)/6$	0,25
$S \rightarrow a_2 A_2$	$p(S \rightarrow a_2 A_2) = (0,5 * 4)/24$	0,08
$S \rightarrow a_3 A_3$	$p(S \rightarrow a_3 A_3) = (0,5 * 5)/24$	0,11
$S \rightarrow a_4 A_4$	$p(S \rightarrow a_4 A_4) = (0,5 * 4)/24 + (0,5 * 1)/6$	0,17
$S \rightarrow a_5 A_5$	$p(S \rightarrow a_5 A_5) = (0,5 * 5)/24 + (0,5 * 3)/6$	0,35
$S \rightarrow a_6 A_6$	$p(S \rightarrow a_6 A_6) = (0,5 * 2)/24$	0,35


Transición producción (visitas de cada Nodo origen al siguiente Nodo destino)		
$A_1 \rightarrow a_2 A_2$	$p(A_1 \rightarrow a_2 A_2) = 1/4$	0,25
$A_1 \rightarrow a_5 A_5$	$p(A_1 \rightarrow a_5 A_5) = 2/4$	0,50
$A_2 \rightarrow a_3 A_3$	$p(A_2 \rightarrow a_3 A_3) = 3/4$	0,75
$A_2 \rightarrow a_4 A_4$	$p(A_2 \rightarrow a_4 A_4) = 1/4$	0,25
$A_3 \rightarrow a_4 A_4$	$p(A_3 \rightarrow a_4 A_4) = 2/5$	0,40
$A_3 \rightarrow a_6 A_6$	$p(A_3 \rightarrow a_6 A_6) = 1/5$	0,20
$A_4 \rightarrow a_1 A_1$	$p(A_4 \rightarrow a_1 A_1) = 2/4$	0,50
$A_4 \rightarrow a_6 A_6$	$p(A_4 \rightarrow a_6 A_6) = 1/4$	0,25
$A_5 \rightarrow a_2 A_2$	$p(A_5 \rightarrow a_2 A_2) = 3/5$	0,60
$A_5 \rightarrow a_3 A_3$	$p(A_5 \rightarrow a_3 A_3) = 2/5$	0,40

Final producción (veces Nodo al final)		
$A_1 \rightarrow F$	$p(A_1 \rightarrow F) = 1/4$	0,25
$A_3 \rightarrow F$	$p(A_3 \rightarrow F) = 2/5$	0,40
$A_4 \rightarrow F$	$p(A_4 \rightarrow F) = 1/4$	0,25
$A_6 \rightarrow F$	$p(A_6 \rightarrow F) = 2/2$	1,00

Representamos en una única tabla las probabilidades de producción de cada una de las etapas (inicio, transición y final):

Inicio producción		Transición producción		Final producción	
S $\rightarrow$ a ₁ A ₁	0,25	A ₁ $\rightarrow$ a ₂ A ₂	0,25	A ₁ $\rightarrow$ F	0,25
S $\rightarrow$ a ₂ A ₂	0,08	A ₁ $\rightarrow$ a ₅ A ₅	0,50	A ₃ $\rightarrow$ F	0,40
S $\rightarrow$ a ₃ A ₃	0,11	A ₂ $\rightarrow$ a ₃ A ₃	0,75	A ₄ $\rightarrow$ F	0,25
S $\rightarrow$ a ₄ A ₄	0,17	A ₂ $\rightarrow$ a ₄ A ₄	0,25	A ₆ $\rightarrow$ F	1,00
S $\rightarrow$ a ₅ A ₅	0,35	A ₃ $\rightarrow$ a ₄ A ₄	0,40		
S $\rightarrow$ a ₆ A ₆	0,35	A ₃ $\rightarrow$ a ₆ A ₆	0,20		
		A ₄ $\rightarrow$ a ₁ A ₁	0,50		
		A ₄ $\rightarrow$ a ₆ A ₆	0,25		
		A ₅ $\rightarrow$ a ₂ A ₂	0,60		
		A ₅ $\rightarrow$ a ₃ A ₃	0,40		

De acuerdo a la tabla, podemos representar el grafo:



Bueno, ¿y ahora esto para qué sirve?

En primer lugar, permite estimar la probabilidad de cualquier 'navigation trails' todavía no producido.

Esto es útil para:

- Calcular la probabilidad de llegar a una cierta página si el usuario está en una página dada.
- La prueba de aplicaciones con los trails más comunes.
- El diseño ajustado a estos trails más comunes.
- La detección de usuarios anómalos (aquellos que realizan trails con muy baja probabilidad).

En segundo lugar, y más importante, nos interesa ver aquellos "patrones de navegación".