

Tema 5

Red de Area local

Latencia y ancho de banda en redes de alta prestación.

Diseño de Redes switcheadas: 1GBE y 10GBE, cobre y fibra. Infiniband.

REDES DE DATOS – LSI - Departamento de Informática
Facultad de Ciencias Exactas, Naturales y Agrimensura

5	Tema 5 Red Local:
5.1	Latencia y ancho de banda en redes de alta prestación. Diseño de Redes switcheadas: 1GBE y 10GBE, cobre y fibra. Infiniband.
	Kurose, capítulo 6.4.2 y 6.4.3

Capa de enlace en redes de área local

Se ha visto, que la capa de red proporciona un servicio de comunicaciones entre dos **Hosts**. La ruta de comunicación está compuesta por una serie de enlaces de comunicaciones, que comienzan en el host de origen, pasan a través de una serie de routers y terminan en el host de destino.

En una red de área local, el objetivo de comunicación, es asegurar múltiples y simultáneas comunicaciones entre **Nodos** conectados a un único canal de enlace.

Ethernet, es por lejos, la tecnología de área local mas utilizada como proveedora de enlace a gran velocidad y capacidad.

Ethernet es utilizada en redes de área local, para conectar múltiples sistemas clientes con servidores de aplicaciones informáticas; éstos difunden servicios informáticos sobre la red de Acceso, que los clientes consumen.

- Ethernet de 1Gb proporciona:
 - Ancho de Banda dedicado en cada puerto.
 - Ancho de Banda agregado para conversaciones simultáneas.
 - Tiempos de Respuestas consistentes.

La LAN Ethernet original fue inventada a mediados de la década de 1970 por Bob Metcalfe y David Boggs.

Switching Ethernet - latencia

- En redes informáticas de datos se denomina **latencia** a la suma de retardos temporales dentro de una red.
- **El retardo** es producido por la demora en la propagación y transmisión de paquetes.
- No importa en dónde estén alojados nuestros servidores, existe siempre un cierto grado de **latencia** entre esos servidores y sus usuarios, dado que la información se transmite a través de conmutadores (switches), entre redes (routers) y a lo largo de rutas globales de fibra óptica.
- Analizar la latencia implica entender la latencia que existe en la infraestructura y aplicaciones, qué niveles de latencia puede alcanzar y el costo que implica las decisiones que tome.
- 2 segundos es el límite de referencia bajo el cual se debe aspirar para mantener la velocidad de carga de su página. En un análisis de datos de Google Analytics en 2012, Google encontró que la velocidad de carga media de una página es de 2,7 segundos (4,8 segundos para móviles).
- El análisis de la latencia ocasionada por la ubicación de las redes y servidores se puede obtener mediante el uso de un traceroute desde su servidor.
- Factores que influyen en la latencia de una red:

El tamaño de los paquetes transmitidos.





El tamaño de los buffers dentro de los equipos de conectividad.

Switching Ethernet - latencia

- **Latencia** es una forma de decir demora.
- *En relación a los switches, nos preocupa esencialmente cuánto tiempo permanecerá un paquete de datos en el switch desde su entrada hasta su salida.*
- Naturalmente, esta demora se agrega a la que ocurre en puntos de la red entre el usuario final y la aplicación destino.
- La latencia de un switch es causada por factores asociados, directa o indirectamente, con la arquitectura interna del switch. En algún punto, un recurso queda limitado y los paquetes de datos se detienen esperando en búferes para acceder a ese recurso. El reloj sigue avanzado, y su resultado es la latencia.
- Switches de gama alta poseen mas funcionalidades que simplemente conmutar paquetes en la capa 2. Switches de 10 GbE ofrecen conmutación en capas de la 4 a la 7, lo que requiere una inspección más profunda del contenido del paquete; más aun cuando se producen descargas SSL: la carga de trabajo criptográfica consume gran parte de la potencia de procesamiento de un switch haciendo que aumente su latencia.

Gigabit Ethernet – conceptos

Frame Ethernet



Switching Ethernet – Tecnologías

versiones diferentes de Ethernet:

10BASE-T,

10BASE-2,

100BASE-T,


1000BASE-T,

1000BASE-LX,

10GBASE-T,

40GBASE-T,

100GBASE-T



1000Base-T: transmisión full-duplex a través de los 4 pares del cable UTP Cat5 o superior

Las tecnologías han sido estandarizadas a lo largo de los años por el grupo de trabajo IEEE 802.3 CSMA/CD (Ethernet) [IEEE 802.3 2012].

Gigabit Ethernet – conceptos

Rendimiento


	Interfaz 1Gb Ethernet	Interfaz 40Gb Infiniband
ping -i0.05 -c20 -s30	20 packets transmitted, time 979ms rtt min/avg/max/mdev = 0.416/ 0.658 /2.583/0.535 ms	20 packets transmitted, time 988ms rtt min/avg/max/mdev = 0.044/0.057/ 0.065 /0.010 ms
ping -i0.05 -c20 -s300	20 packets transmitted, time 978ms rtt min/avg/max/mdev = 0.570/ 0.707 /1.568/0.263 ms	20 packets transmitted, time 985ms rtt min/avg/max/mdev = 0.054/0.060/0.088/0.009 ms
ping -i0.05 -c200 -s 4096	20 packets transmitted, time 960ms rtt min/avg/max/mdev = 2.566/ a /3.450/0.286 ms	20 packets transmitted, time 981ms rtt min/avg/max/mdev = 0.077/0.088/0.118/0.018 ms
ping -i0.05 -c200 -s 20000	20 packets transmitted, time 954ms rtt min/avg/max/mdev = 5.877/ 6.022 /6.676/0.201 ms	20 packets transmitted, time 986ms rtt min/avg/max/mdev = 0.113/0.123/0.189/0.021 ms

Switching Ethernet – Técnicas de envío

Cut-Through

El switch comenzará a enviar datos después de que éste reciba la dirección de destino del Frame. Así, Frames con Errores no pueden ser detectados, por lo que este método puede impactar en el rendimiento de una red, al enviar Frames corruptos o truncados.

"Bad" Frames pueden originar Tormentas de Broadcasts Broadcasts Storms en que muchos de los dispositivos de la red responderán a los Frames corruptos simultáneamente.




<https://www.networkacademy.io/ccna/ethernet/store-and-forward-vs-cut-through-switching>

Switching Ethernet – Técnicas de envío

Store-and-Forward

El Switch esperará hasta que todo el Frame haya arribado, antes de tomar una decisión de envío. Este proceso asegura que la red de destino no se verá afectada por Frames corruptos o truncados, pero con la desventaja que tiene mayor latencia que cut-through.



<https://www.networkacademy.io/ccna/ethernet/store-and-forward-vs-cut-through-switching>


Switching Ethernet – Cascada y Stacking

Para los casos en que la infraestructura cuente con mas de un switch y es necesaria su interconexión, se puede optar por alguno de estos metodos de conexión.

Stack es para interconectar 2 o más switches utilizando un cable especial (tipo SCSI o HDMI) instalado generalmente en la parte posterior del chasis del switch.

Cascada utiliza los puertos del switch Ethernet para conectarse a un segundo Switch mediante un cable UTP. Se dice que el segundo Switch está “cascadeado”.

Comparando ambos métodos, el hacer Stack mejora el rendimiento del proceso de switching, eliminando el problema del contador de saltos.



Switching Ethernet - Características

Gestionabilidad

- ◆ Switch Gestionable, significa que el Switch tiene características de administración y está habilitado para recibir una dirección IPv4 o IPv6, de manera tal que pueda ser Monitoreado en forma remota.
- ◆ Posee soporte y gestión de VLAN's, Estadísticas de uso (por puerto, por tamaño de paquetes); Alertas ante ocurrencia de eventos (tormenta de broadcast).
- ◆ Switch No Gestionable, significa que éste dispositivo no permite ningún tipo configuración y todas sus características están en modo "auto".

Port Mirroring

- ◆ Permite monitorear un puerto del switch, enviando el tráfico a un puerto destino (mirror port).
- ◆ Es utilizado para capturar datos con un analizador de protocolos. (IN- OUT).
- ◆ Los puertos de origen y destino deben estar ubicados en el mismo switch.

Switching Ethernet - Características

Port Security

- ▶ Permite controlar las estaciones conectadas a un puerto analizando su MAC.
- ▶ Trabaja en dos modos: Lock y Max-address.
- ▶ Cuando se conecta una MAC desconocida, el puerto puede tomar alguna de estas opciones: Reenvío, Discard, Discard y envío SNMP y discard-shutdown.
- ▶ Se pueden ingresar direcciones MAC manualmente y asignarlos a puertos cuando se encuentre el port-security habilitado.

Link Aggregation (802.3ad)

- ▶ Soporta enlaces activos múltiples, punto-a-punto y “paralelos” entre switches ó entre un switch y un host.
- ▶ “Trunking” permite que un número de puertos se configuren en grupos para poder operar como una única conexión lógica para proveer:
 - ▶ Mayor ancho de banda
 - ▶ Redundancia
 - ▶ Balanceo de carga
- ▶ Implementado a través de LACP, los puertos deben pertenecer a la misma VLAN, no se pueden mezclar velocidades de puertos.

Switching Ethernet – Spanning Tree

Protocolo Spanning Tree

- La implementación de redes basadas en Switching Ethernet, corren peligro de crear bucles o loops en su infraestructura, que como resultado determinan baja performance de la red por reiteradas retransmisión y/o descartes de frames.
- Para evitar esta situación, se ha desarrollado un algoritmo conocido como “Spanning Tree”, estandarizado en la Recomendación IEEE 802.1d. Se busca bloquear los enlaces que cierran los bucles, dejando a la red siempre con una topología del tipo “árbol”, y asegurar de esta manera que no existan bucles.
- El algoritmo reevalúa periódicamente que enlaces hay que bloquear o rehabilitar para tener acceso a todos los equipos sin crear bucles. Permite valorar los enlaces con “pesos”, cuando existen bucles es posible configurar a priori que enlaces serán los principales y que enlaces quedarán bloqueados.
- El standard de STP es 802.1d y de Rapid Spanning Tree Protocol (RSTP) el 802.1w
- Al crear redundancia en las conexiones para obtener alta disponibilidad, creamos bucles que podrían afectar a la red al crearse bucles. Los bucles se detectan porque los switches reciben las mismas BPDU's o actualizaciones de los switches por diferentes interfaces.
- STP trabaja de forma distribuida en todos los switches de la red enviando cada uno de ellos sus actualizaciones mediante BPDU (Bridge Protocol Data Units).

Switching Ethernet – Spanning Tree

Características:

- **Switch raíz:** Mediante el algoritmo STA, se busca un switch con características determinadas, que lo promocionará como root. Los atributos que definen la prioridad de un switch vienen en un intercambio de datos BPDU, donde un campo llamado BID contiene el identificador del switch, su MAC y otro valor. El que tiene un valor BID menor, es el switch raíz. Si el BID es igual en los switches cercanos, es la menor MAC la que define el switch raíz.
- **Puerto raíz:** (Root Port o RP) Tras hallar el switch raíz, los otros switches buscan cual es el mejor camino para llegar al switch raíz identificando los mejores puertos según su velocidad. Mediante el comando spanning-tree cost valor se puede definir una prioridad particular.
- **Puerto designado:** (Designated Port o DP) es el puerto que está al otro lado de un puerto raíz. Los puertos del switch raíz son puertos designados.
- **Puerto alternativo o de respaldo:** son los puertos candidatos a ser deshabilitado en la envía de datos para evitar los bucles. En RSTP si el root port principal falla, este se convierte en root port.
- **Backup port:** Es el puerto paralelo al root port en el mismo switch. Si el root port falla, este se convierte en root port. Mientras está en modo backup port, está también en discarding state.

Switching Ethernet – Spanning Tree

Puertos

- **Puertos deshabilitados:** un puerto deshabilitado es un puerto de switch que está desactivado.
- **Per-VLAN Spanning Tree (PVST)** tiene un STP para cada VLAN mediante protocolo ISL. El propietario de este protocolo es CISCO.
- **Bridge ID:** Es el identificador del SWITCH.
- **Link cost en STP:** Es un valor asociado a la velocidad del enlace.
- **Path cost en RSTP:** Es un valor que representa la velocidad en atravesar todos los elementos hasta el root switch.

Tecnología de Capa de enlace InfiniBand

Infiniband, sus principales ventajas

Features:

- Remote Direct Memory Access (RDMA) – zero copy
- Kernel bypass
- Highly scalable (10K's of nodes)
- Message based transactions
- Credit based flow control

Performance

- High BW (56 Gb/sec)
- Low latency (700 nsec)
- High message rate (137 Mpps)
- The lower 4 OSI layers implemented in HW

Other


- Industry Standard
- Developed as Open Source (in *NIX)
- Inbox in several OS's

Infiniband, conceptos de arquitectura

InfiniBand (IB) es una tecnología de redes desarrollada por la InfiniBand Trade Association en 1999. Se utiliza para computación de alto rendimiento y en centros de datos empresariales. Sus características incluyen alto rendimiento, baja latencia, calidad de servicio y conmutación por error.


La unidad de arquitectura InfiniBand (IBA) completa más pequeña es una subred. Una subred consta de nodos finales (por ejemplo, servidores), conmutadores, enlaces de cobre o fibra y un administrador de subred.

Los nodos finales utilizan los denominados adaptadores de canal (CA) para conectarse a los enlaces. Hay adaptadores de canal de host (HCA) y adaptadores de canal de destino (TCA). Los usuarios pueden acceder a los HCA, los TCA no. El administrador de subred tiene una visión general y administra toda la subred.



Infiniband, concepto técnico

InfiniBand permite que una aplicación se comuniquen directamente con otra aplicación. Esto significa que una aplicación no necesita depender del sistema operativo para transferir mensajes.




InfiniBand crea un canal que conecta directamente una aplicación en su espacio de direcciones virtual a una aplicación en otro espacio de direcciones virtuales

<https://blog.zhaw.ch/icclab/infiniband-an-introduction-simple-ib-verbs-program-with-rdma-write/>

Infiniband, modo de conexión


- ▶ Las CA se comunican entre sí mediante colas de trabajo.
- ▶ Hay tres tipos de colas de trabajo: Enviar, Recibir y Completar.
- ▶ Las colas de envío y recepción siempre se utilizan como pares de colas (QP).
- ▶ Un QP particular en una CA es el destino o la fuente de todos los mensajes.
- ▶ Cada QP también tiene un puerto asociado que es una abstracción de la conexión de una CA a un enlace.



Queue Pairs (send/receive) in the Channel Adapters

<https://blog.zhaw.ch/icclab/infiniband-an-introduction-simple-ib-verbs-program-with-rdma-write/>

Infiniband, modelo de capas



<http://www.mcs.anl.gov/~balaji/pubs/2010/ispass/ispass10.ipoib.pdf> Redes de Datos - Facena UNNE - Curso 2024

Infiniband, conceptos de arquitectura iba

Semánticas de comunicación: Channel Semantic (CS) y Remote Direct Memory Access (RDMA).

RDMA permite a los procesos el acceso a memoria de un proceso en un nodo remoto sin intervención del CPU del nodo remoto (lectura o escritura).

Modos de transporte:

Reliable Connection (RC),

Unreliable Connection (UC),

Unreliable Datagram (UD), es el que mejor se acopla a las necesidades de IP.

Reliable Datagram (RD);

Mediante la pila TCP/IP, los datos se divide en unidades de paquetes de tamaño, proporciona control y la fiabilidad de flujo. La pila IP a continuación, añade la información necesaria para el encaminamiento correcto del paquete a su destino. Por lo tanto, el adaptador de red se supone que es un dispositivo de entrega 'no confiable', sin capacidades adicionales.

Se hace necesaria la convergencia entre InfiniBand y Ethernet. IPoIB es la interfaz por la que los programas basados en socket IP operan sobre IB, aporta un importante rendimiento en entornos de centros de datos actuales para entender los beneficios que podrían derivarse de entornos de red híbridos.

Infiniband, dispositivos de conexión

Conexión por cobre o Fibra



Adaptadores de Host



Interconexión - Switches



InfiniBand: Encapsulación IP en IB

IPoIB puede funcionar en dos modos de operación:

- **modo Conectado**
- **modo de Datagramas**

De forma predeterminada, IPoIB trabaja en modo en datagramas.

Para una mejor escalabilidad y el rendimiento se recomienda utilizar el modo de datagramas.

El modo puede cambiarse al modo Conectado editando el archivo `/etc/infiniband/openib.conf` y el establecimiento de `'SET_IPOIB_CM = yes'`

`$ ibstat` `$ ibstatus`

`$ ibnetdiscovery` `$ ibping`